



UNIVERSIDADE ESTADUAL DE SANTA CRUZ — UESC
DEPARTAMENTO DE ENGENHARIAS E COMPUTAÇÃO — DEC
CURSO DE ENGENHARIA QUÍMICA

LABORATÓRIO DE INSTRUMENTAÇÃO COMPUTACIONAL

LABORATÓRIO 02

MEDIÇÃO DE TEMPERATURA

Prof. Dr. E.R.Edwards

Exercício 1 – Estabilidade térmica em banho controlado

No laboratório de Instrumentação existe um banho térmico mantido a 25°C por um controlador PID. Dois sensores foram inseridos no banho para avaliar sua estabilidade térmica:

- Sensor A — modelo industrial de alta precisão;
- Sensor B — sensor comercial de menor custo.

Após 10 segundos de medição, os valores foram registrados no arquivo `banho_estavel.csv`. O objetivo é determinar qual sensor apresenta maior estabilidade térmica, isto é, menor variação e menor erro em relação à temperatura real do banho.

O arquivo `banho_estavel.csv` contém as seguintes colunas:

- `tempo_s`: tempo de aquisição dos dados, em segundos;
- `sensor_A_C`: temperatura indicada pelo Sensor A, em $^{\circ}\text{C}$;
- `sensor_B_C`: temperatura indicada pelo Sensor B, em $^{\circ}\text{C}$.

Tarefas

1. Carregue o arquivo `banho_estavel.csv` utilizando a biblioteca Pandas.
2. Calcule, para cada sensor:
 - a temperatura média;
 - o desvio padrão;
 - o erro absoluto médio em relação à temperatura real do banho, considerada igual a 25°C .
3. Construa um gráfico das temperaturas medidas pelos sensores A e B em função do tempo, incluindo uma linha horizontal correspondente à temperatura real do banho.
4. A partir dos resultados numéricos e do gráfico obtido, determine qual sensor apresenta maior estabilidade térmica e justifique sua resposta.

Dados experimentais

Os dados registrados no arquivo `banho_estavel.csv` são apresentados a seguir:

```
tempo_s,sensor_A_C,sensor_B_C
0,25.01,24.98
1,25.03,25.10
2,24.99,25.05
```



Figura 1: Montagem experimental utilizada para avaliar a estabilidade térmica de dois sensores de temperatura em um banho controlado a 25 °C. O controlador PID mantém o banho na temperatura desejada, enquanto os sensores A e B são utilizados para registrar as medições ao longo do tempo.

3,25.02,25.08
 4,25.00,25.12
 5,25.01,25.09
 6,25.02,25.11
 7,24.98,25.07
 8,25.00,25.10
 9,25.01,25.08

Resolução computacional

A análise dos dados será realizada utilizando as bibliotecas NumPy, Pandas e Matplotlib. Inicialmente, os dados experimentais serão carregados com o Pandas. Em seguida, serão determinadas as grandezas estatísticas utilizadas na comparação dos sensores e, por fim, será construído o gráfico das temperaturas em função do tempo.

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

```
# -----
# 1. Leitura do arquivo CSV
# -----
```

```

tabela = pd.read_csv("banho_estavel.csv")

# -----
# 2. Estatísticas dos sensores
# -----

media_A = tabela["sensor_A_C"].mean()
media_B = tabela["sensor_B_C"].mean()

desvio_A = tabela["sensor_A_C"].std()
desvio_B = tabela["sensor_B_C"].std()

# Temperatura real do banho
T_real = 25.00

erro_A = np.abs(tabela["sensor_A_C"] - T_real).mean()
erro_B = np.abs(tabela["sensor_B_C"] - T_real).mean()

# -----
# 3. Apresentação dos resultados
# -----

print("-----")
print("Sensor A:")
print("-----")
print(f"Média = {media_A:.3f} °C")
print(f"Desvio padrão = {desvio_A:.4f} °C")
print(f"Erro absoluto médio = {erro_A:.4f} °C")

print()

print("-----")
print("Sensor B:")
print("-----")
print(f"Média = {media_B:.3f} °C")
print(f"Desvio padrão = {desvio_B:.4f} °C")
print(f"Erro absoluto médio = {erro_B:.4f} °C")

# -----

```

```

# 4. Gráfico comparativo
# -----

plt.figure(figsize=(8, 4))

plt.plot(
    tabela["tempo_s"],
    tabela["sensor_A_C"],
    color="black",
    linestyle="-",
    marker="o",
    label="Sensor A"
)

plt.plot(
    tabela["tempo_s"],
    tabela["sensor_B_C"],
    color="black",
    linestyle="-.",
    marker="s",
    label="Sensor B"
)

plt.axhline(
    T_real,
    color="black",
    linestyle="--",
    label="Temperatura real (25 °C)"
)

plt.xlabel("Tempo (s)")
plt.ylabel("Temperatura (°C)")
plt.title("Comparação de sensores em banho térmico estável")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

```

Resultados obtidos

Após a execução do código, o console deverá apresentar:

Sensor A:

Média = 25.007 °C

Desvio padrão = 0.0149 °C

Erro absoluto médio = 0.0130 °C

Sensor B:

Média = 25.078 °C

Desvio padrão = 0.0399 °C

Erro absoluto médio = 0.0820 °C

O gráfico obtido é apresentado a seguir:




Figura 2: Comparação das medições realizadas pelos sensores A e B em um banho térmico controlado a 25 °C. O Sensor A é representado por linha contínua com marcadores circulares, enquanto o Sensor B é representado por linha traço-ponto com marcadores quadrados. A linha horizontal tracejada representa a temperatura real do banho.

Análise dos resultados

Ao observar o gráfico das medições, nota-se que o **Sensor A** apresenta valores que oscilam suavemente em torno da temperatura real do banho, igual a 25 °C. As variações são pequenas, da ordem de centésimos de grau, indicando baixa variabilidade e boa estabilidade térmica.

O valor médio obtido para o Sensor A é:

$$\overline{T}_A = 25,007^\circ\text{C},$$

com desvio padrão:

$$s_A = 0,0149^\circ\text{C},$$

e erro absoluto médio:

$$E_A = 0,0130^\circ\text{C}.$$

Por outro lado, o **Sensor B** apresenta medições predominantemente acima de 25°C e maior dispersão entre os valores registrados. Para esse sensor, foram obtidos:

$$\overline{T}_B = 25,078^\circ\text{C},$$

$$s_B = 0,0399^\circ\text{C},$$

e

$$E_B = 0,0820^\circ\text{C}.$$

A comparação dos resultados mostra que:

$$s_A < s_B$$

e

$$E_A < E_B.$$

Portanto, para o conjunto de dados analisado, o Sensor A apresenta menor dispersão das medições e menor erro em relação à temperatura real do banho.

Conclusão

Com base nos resultados numéricos e no comportamento observado no gráfico, conclui-se que o **Sensor A apresenta maior estabilidade térmica**. Suas medições permanecem mais próximas da temperatura real do banho e apresentam menor dispersão quando comparadas às medições do Sensor B.

Exercício 2 – Resposta Dinâmica: Qual Sensor Reage Mais Rápido?

Em um experimento de laboratório, dois sensores de temperatura, denominados Sensor A e Sensor B, foram submetidos simultaneamente a uma mudança rápida de temperatura.

Inicialmente, ambos os sensores encontravam-se em equilíbrio térmico a 25 °C. Em seguida, foram submetidos a um meio cuja temperatura foi elevada rapidamente para aproximadamente 50 °C.

Durante o experimento, as temperaturas indicadas pelos dois sensores foram registradas ao longo do tempo no arquivo `aquecimento_rapido.csv`.

O arquivo contém as seguintes colunas:

- `tempo_s`: tempo de aquisição dos dados, em segundos;
- `sensor_A_C`: temperatura indicada pelo Sensor A, em °C;
- `sensor_B_C`: temperatura indicada pelo Sensor B, em °C.

O objetivo deste exercício é utilizar ferramentas de computação científica para analisar a resposta dinâmica dos sensores e determinar qual deles responde mais rapidamente à mudança de temperatura.

Tarefas

1. Carregue o arquivo `aquecimento_rapido.csv` utilizando a biblioteca Pandas e visualize os dados experimentais.
2. Utilizando a biblioteca NumPy, calcule numericamente a taxa de variação da temperatura,

$$\frac{dT}{dt},$$

para os sensores A e B.

3. Determine a temperatura correspondente a 90% da variação total provocada pelo aquecimento.
4. Determine, para cada sensor, o primeiro instante de medição no qual a temperatura indicada atinge ou ultrapassa 90% da variação total.
5. Construa um gráfico da temperatura em função do tempo para os dois sensores.
6. Construa um segundo gráfico mostrando a taxa de variação da temperatura dT/dt em função do tempo.
7. A partir dos resultados numéricos e dos gráficos obtidos, identifique qual sensor apresenta resposta dinâmica mais rápida e justifique sua resposta.

Dados experimentais

Os dados registrados no arquivo `aquecimento_rapido.csv` são apresentados a seguir:

```
tempo_s,sensor_A_C,sensor_B_C
0,25.0,25.0
1,28.5,26.2
2,33.0,28.0
3,38.2,30.5
4,42.0,33.0
5,45.0,36.0
6,47.0,39.5
7,48.0,42.0
8,49.0,44.0
9,50.0,46.0
10,50.0,47.0
11,50.0,48.0
12,50.0,49.0
13,50.0,49.5
14,50.0,50.0
```

Resolução computacional

A resolução do problema será realizada de forma progressiva, utilizando Python como ferramenta para o tratamento e a análise dos dados experimentais. Cada etapa do código estará diretamente relacionada a uma das tarefas propostas anteriormente.

Inicialmente, serão importadas as bibliotecas necessárias e os dados experimentais serão carregados com o Pandas. Em seguida, o NumPy será utilizado para determinar numericamente a taxa de variação da temperatura e auxiliar na análise da resposta dinâmica dos sensores. Por fim, o Matplotlib será empregado na construção dos gráficos, permitindo comparar visualmente o comportamento dos sensores A e B.

1. Importação das bibliotecas e leitura dos dados

```
# -*- coding: utf-8 -*-
"""
Exercício - Resposta dinâmica de sensores de temperatura

Objetivo:
Comparar a resposta dinâmica de dois sensores submetidos
a um aquecimento rápido.
"""
```

```

# -----
# 1. Importação das bibliotecas
# -----

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# -----
# 2. Leitura do arquivo CSV
# -----

tabela = pd.read_csv("aquecimento_rapido.csv")

print("\nDados experimentais:")
print(tabela)

```

Após a execução, os dados experimentais serão apresentados no console, permitindo verificar se o arquivo foi carregado corretamente.

2. Cálculo da derivada numérica

A derivada da temperatura em relação ao tempo,

$$\frac{dT}{dt},$$

representa a taxa de variação da temperatura medida pelo sensor. Como a temperatura é expressa em graus Celsius e o tempo em segundos, a unidade de dT/dt será:

$$\frac{^{\circ}\text{C}}{\text{s}}.$$

Por exemplo, um valor

$$\frac{dT}{dt} = 4^{\circ}\text{C/s}$$

indica que, naquele instante, a temperatura medida está variando a uma taxa aproximada de 4°C por segundo.

Como os dados experimentais foram registrados em instantes discretos, não dispomos de uma função analítica contínua $T(t)$ para calcular diretamente sua derivada. Dessa forma, a taxa de variação da temperatura deve ser estimada numericamente a partir dos valores medidos.

De maneira geral, podemos escrever:

$$\frac{dT}{dt} \approx \frac{\Delta T}{\Delta t}.$$

Para um ponto interno i da série de dados, existem valores de temperatura registrados antes e depois do instante analisado. Uma aproximação por diferença central pode ser escrita como:

$$\left. \frac{dT}{dt} \right|_i \approx \frac{T_{i+1} - T_{i-1}}{t_{i+1} - t_{i-1}}$$

em que:

- T_{i-1} representa a temperatura medida no ponto anterior;
- T_{i+1} representa a temperatura medida no ponto posterior;
- t_{i-1} representa o instante correspondente ao ponto anterior;
- t_{i+1} representa o instante correspondente ao ponto posterior.

Por exemplo, para determinar a derivada da temperatura do Sensor A no instante $t = 1$ s, utilizamos o ponto anterior, $t = 0$ s, e o ponto posterior, $t = 2$ s.

Dos dados experimentais:

$$T_0 = 25,0^\circ\text{C}, \quad t_0 = 0 \text{ s},$$

e

$$T_2 = 33,0^\circ\text{C}, \quad t_2 = 2 \text{ s}.$$

Assim:

$$\left. \frac{dT}{dt} \right|_{t=1} \approx \frac{T_2 - T_0}{t_2 - t_0} = \frac{33,0 - 25,0}{2 - 0} = 4,0^\circ\text{C/s}.$$

Entretanto, essa aproximação não pode ser aplicada diretamente ao primeiro ponto da série, pois não existe uma medição anterior a $t = 0$. Nesse caso, a derivada é estimada utilizando os dois primeiros pontos disponíveis, caracterizando uma aproximação por diferença para a frente:

$$\left. \frac{dT}{dt} \right|_0 \approx \frac{T_1 - T_0}{t_1 - t_0}$$

Para o Sensor A:

$$T_0 = 25,0^\circ\text{C}, \quad t_0 = 0 \text{ s},$$

e

$$T_1 = 28,5^\circ\text{C}, \quad t_1 = 1 \text{ s}.$$

Portanto:

$$\left. \frac{dT}{dt} \right|_{t=0} \approx \frac{28,5 - 25,0}{1 - 0} = 3,5^\circ\text{C/s}.$$

Observe que o denominador não corresponde ao valor do tempo $t_0 = 0$, mas à variação do tempo entre duas medições:

$$\Delta t = t_1 - t_0 = 1 - 0 = 1 \text{ s}.$$

Portanto, não ocorre divisão por zero. A derivada da temperatura não corresponde à razão T/t , mas à razão entre variações de temperatura e tempo.

Situação semelhante ocorre no último ponto da série. Como não existe uma medição posterior, a derivada é estimada utilizando os dois últimos pontos disponíveis, caracterizando uma aproximação por diferença para trás:

$$\left. \frac{dT}{dt} \right|_n \approx \frac{T_n - T_{n-1}}{t_n - t_{n-1}}$$

Dessa forma, o procedimento pode ser resumido como:

Primeiro ponto	→	diferença para a frente
Pontos internos	→	diferença central
Último ponto	→	diferença para trás

A função `np.gradient()` do NumPy realiza automaticamente essas estimativas numéricas, permitindo obter um valor aproximado de dT/dt para cada instante registrado no conjunto de dados.

```
# -----
# 3. Cálculo da derivada numérica da temperatura
# -----

tabela["dTdt_A_C_s"] = np.gradient(
    tabela["sensor_A_C"],
    tabela["tempo_s"]
)

tabela["dTdt_B_C_s"] = np.gradient(
    tabela["sensor_B_C"],
    tabela["tempo_s"]
)
```

```
print("\nTabela com as derivadas:")
print(tabela)
```

Fisicamente, os valores calculados podem ser interpretados da seguinte forma:

- valores elevados e positivos de dT/dt indicam aumento rápido da temperatura medida;
- valores positivos próximos de zero indicam que a temperatura ainda aumenta, porém mais lentamente;
- quando dT/dt se aproxima de zero, a leitura do sensor tende a uma condição aproximadamente estacionária.

3. Determinação da temperatura correspondente a 90%

Para comparar quantitativamente a rapidez de resposta dos sensores, será utilizado o tempo necessário para que cada um atinja 90% da variação total de temperatura provocada pelo aquecimento.

A temperatura inicial do experimento é:

$$T_0 = 25^\circ\text{C},$$

enquanto a temperatura final é:

$$T_f = 50^\circ\text{C}.$$

A variação total de temperatura é:

$$\Delta T = T_f - T_0,$$

resultando em:

$$\Delta T = 50 - 25 = 25^\circ\text{C}.$$

Noventa por cento dessa variação corresponde a:

$$0,90\Delta T = 0,90(25) = 22,5^\circ\text{C}.$$

Como o experimento se inicia em 25°C , a temperatura correspondente a 90% da resposta é:

$$T_{90} = T_0 + 0,90(T_f - T_0).$$

Substituindo os valores:

$$T_{90} = 25 + 0,90(50 - 25) = 47,5 \text{ }^{\circ}\text{C}.$$

Portanto:

$$T_{90} = 47,5 \text{ }^{\circ}\text{C}.$$

É importante observar que não estamos calculando simplesmente 90% da temperatura final, isto é,

$$0,90T_f.$$

O valor de 90% é calculado sobre a **variação de temperatura** entre as condições inicial e final do experimento.

Como os sensores A e B foram submetidos ao mesmo processo térmico, ambos possuem as mesmas condições inicial e final. Consequentemente, o critério T_{90} é o mesmo para os dois sensores.

A implementação em Python pode ser realizada da seguinte forma:

```
# -----
# 4. Temperaturas inicial e final do experimento
# -----

T0 = 25.0
Tf = 50.0

# -----
# 5. Temperatura correspondente a 90% da resposta
# -----

T90 = T0 + 0.90 * (Tf - T0)

print("\nTemperatura correspondente a 90% da resposta:")
print(f"T90 = {T90:.2f} °C")
```

Após a execução, será apresentado no console:

```
Temperatura correspondente a 90% da resposta:
T90 = 47.50 °C
```

O resultado computacional coincide com o valor obtido manualmente:

$$T_{90} = 47,5 \text{ }^{\circ}\text{C}.$$

4. Determinação do tempo de resposta

Uma vez estabelecido o valor de T_{90} , podemos determinar o tempo de resposta de cada sensor. Neste exercício, será considerado como t_{90} o **primeiro instante de medição** no qual a temperatura indicada pelo sensor atinge ou ultrapassa:

$$T_{90} = 47,5^{\circ}\text{C}.$$

No código Python, utilizaremos o mesmo valor de T90 para localizar, na tabela de dados experimentais, o primeiro instante em que cada sensor apresenta uma temperatura maior ou igual a $47,5^{\circ}\text{C}$:

```
# -----  
# 6. Determinação do tempo de resposta  
# -----  
  
tempo_90_A = tabela.loc[  
    tabela["sensor_A_C"] >= T90,  
    "tempo_s"  
].iloc[0]  
  
tempo_90_B = tabela.loc[  
    tabela["sensor_B_C"] >= T90,  
    "tempo_s"  
].iloc[0]  
  
print("\nTempo para atingir 90% da resposta:")  
print("Sensor A:", tempo_90_A, "s")  
print("Sensor B:", tempo_90_B, "s")
```

A expressão

```
tabela["sensor_A_C"] >= T90
```

verifica, para cada linha da tabela, se a temperatura medida pelo Sensor A é maior ou igual a T_{90} . Em seguida, o comando

```
.iloc[0]
```

seleciona o primeiro valor da coluna `tempo_s` que satisfaz essa condição. O mesmo procedimento é realizado para o Sensor B.

Para o Sensor A:

$$T_A(6) = 47^{\circ}\text{C}$$

e

$$T_A(7) = 48^\circ\text{C}.$$

Como

$$47 < 47,5 \quad \text{e} \quad 48 \geq 47,5,$$

o primeiro instante de medição no qual o Sensor A atinge ou ultrapassa T_{90} é:

$$\boxed{t_{90,A} = 7 \text{ s}}.$$

Para o Sensor B:

$$T_B(10) = 47^\circ\text{C}$$

e

$$T_B(11) = 48^\circ\text{C}.$$

Como

$$47 < 47,5 \quad \text{e} \quad 48 \geq 47,5,$$

o primeiro instante de medição no qual o Sensor B atinge ou ultrapassa T_{90} é:

$$\boxed{t_{90,B} = 11 \text{ s}}.$$

Após a execução do código, o console deverá apresentar:

Tempo para atingir 90% da resposta:

Sensor A: 7 s

Sensor B: 11 s

Portanto:

$$\boxed{t_{90,A} = 7 \text{ s} < t_{90,B} = 11 \text{ s}}$$

Esses valores correspondem aos primeiros instantes registrados no conjunto de dados em que cada sensor atinge ou ultrapassa T_{90} . Como as medições foram realizadas em intervalos de 1 s, não se está determinando, nesta análise, o instante exato de cruzamento entre dois pontos consecutivos.

5. Gráfico das temperaturas

O primeiro gráfico permite comparar diretamente a evolução das temperaturas indicadas pelos sensores A e B ao longo do tempo.


```

# -----
# 7. Gráfico das temperaturas
# -----

plt.figure(figsize=(10, 6))

plt.plot(
    tabela["tempo_s"],
    tabela["sensor_A_C"],
    color="black",
    linestyle="-",
    marker="o",
    label="Sensor A"
)

plt.plot(
    tabela["tempo_s"],
    tabela["sensor_B_C"],
    color="black",
    linestyle="--",
    marker="s",
    label="Sensor B"
)

plt.xlabel("Tempo (s)")
plt.ylabel("Temperatura (°C)")
plt.title("Resposta dinâmica dos sensores de temperatura")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()

```

O gráfico obtido é apresentado a seguir:

6. Gráfico da taxa de variação da temperatura

O segundo gráfico permite analisar como a taxa de variação da temperatura medida por cada sensor evolui durante o processo de aquecimento.

```

# -----
# 8. Gráfico da derivada da temperatura
# -----

```




Figura 3: Evolução da temperatura medida pelos sensores A e B em função do tempo durante o aquecimento de 25 °C a 50 °C.

```
plt.figure(figsize=(10, 6))
```

```
plt.plot(
    tabela["tempo_s"],
    tabela["dTdt_A_C_s"],
    color="black",
    linestyle="-",
    marker="o",
    label="Sensor A"
)
```

```
plt.plot(
    tabela["tempo_s"],
    tabela["dTdt_B_C_s"],
    color="black",
    linestyle="--",
    marker="s",
    label="Sensor B"
)
```

```
plt.xlabel("Tempo (s)")
plt.ylabel("dT/dt (°C/s)")
plt.title("Taxa de variação da temperatura")
```

```
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()
```

O gráfico obtido é apresentado a seguir:




Figura 4: Evolução da taxa de variação da temperatura, dT/dt , dos sensores A e B em função do tempo durante o processo de aquecimento.

7. Análise dos resultados

Os dois sensores foram submetidos à mesma variação de temperatura, de 25°C para 50°C . Entretanto, suas respostas ao longo do tempo são diferentes.

A análise do critério de 90% mostrou que:

$$t_{90,A} = 7 \text{ s}$$

e

$$t_{90,B} = 11 \text{ s.}$$

Portanto:

$$t_{90,A} < t_{90,B}.$$

Isso mostra que o Sensor A necessita de menos tempo para atingir 90% da variação total de temperatura.

O gráfico de temperatura em função do tempo confirma esse comportamento: a curva correspondente ao Sensor A se aproxima mais rapidamente da temperatura final, enquanto o Sensor B apresenta uma evolução mais lenta.

A análise de dT/dt fornece uma informação complementar. Durante os primeiros instantes do aquecimento, o Sensor A apresenta taxas de variação mais elevadas, evidenciando uma resposta mais rápida à mudança térmica. À medida que sua leitura se aproxima de 50°C , os valores de dT/dt diminuem e tendem a zero, indicando a aproximação de uma condição estacionária.

O Sensor B apresenta uma resposta mais gradual, necessitando de um intervalo de tempo maior para se aproximar da temperatura final.

Conclusão

Com base no tempo necessário para atingir 90% da variação total de temperatura, na evolução das curvas de temperatura e na análise da taxa dT/dt , conclui-se que, para o conjunto de dados analisado, o **Sensor A apresenta resposta dinâmica mais rápida**. Essa característica é particularmente importante em aplicações de instrumentação e controle de processos nas quais variações rápidas de temperatura precisam ser detectadas com pequeno atraso.

Exercício 3 – Criogenia: Comparação entre DT-670 e PT100

Em sistemas criogênicos, a medição de temperatura apresenta desafios significativamente diferentes daqueles encontrados em processos industriais operando próximos à temperatura ambiente. À medida que a temperatura diminui, a escolha adequada do sensor torna-se particularmente importante, pois diferentes tecnologias de medição podem apresentar comportamentos distintos em relação à sensibilidade, à faixa de operação e à resposta metrológica.

Neste exercício, será analisado um conjunto de dados didáticos representando medições realizadas em diferentes temperaturas criogênicas utilizando dois sensores:

- **DT-670**: sensor baseado em diodo de silício, utilizado como referência no conjunto de dados analisado;
- **PT100**: sensor resistivo de platina cujas indicações serão comparadas às temperaturas fornecidas pelo DT-670.

O objetivo é utilizar ferramentas de computação científica para investigar a concordância entre as indicações dos dois sensores ao longo da faixa de temperatura considerada. Para isso, serão analisados o erro absoluto, o erro relativo, a dispersão dos dados e a relação entre as temperaturas indicadas pelos sensores. Também será ajustado um modelo de regressão linear, permitindo avaliar quantitativamente a relação existente entre as duas séries de medições.

Os dados utilizados neste exercício são **didáticos e simulados**, construídos especificamente para o desenvolvimento das técnicas de análise computacional apresentadas a seguir. Portanto, não devem ser interpretados como resultados de uma calibração metrológica real nem como especificações metrológicas dos sensores considerados.

Dados experimentais simulados

Os dados estão armazenados no arquivo `criogenia.csv`, que contém as seguintes colunas:

- `ponto`: identificação do ponto de medição;
- `DT670_K`: temperatura indicada pelo DT-670, em kelvin;
- `PT100_K`: temperatura indicada pelo PT100, em kelvin.

O conjunto de dados utilizado no exercício é apresentado a seguir:

```
ponto,DT670_K,PT100_K
1,4.20,4.59
2,5.00,5.29
3,6.00,6.52
4,7.00,7.42
5,8.00,8.52
6,10.00,10.51
7,12.00,12.78
8,15.00,15.81
9,18.00,19.15
10,20.00,21.09
11,22.00,23.33
12,25.00,26.39
13,28.00,29.77
14,30.00,31.83
15,32.00,34.11
16,35.00,37.18
17,38.00,40.57
18,40.00,42.64
19,43.00,46.08
20,46.00,49.23
21,50.00,53.75
```

Observe que os pontos de medição não precisam estar igualmente espaçados. A presença de um número maior de pontos na região de temperaturas mais baixas permite analisar com maior detalhe o comportamento das medições nessa região.

Tarefas

1. Carregue o arquivo `criogenia.csv` utilizando a biblioteca Pandas e visualize os dados disponíveis.
2. Considerando o DT-670 como referência para este conjunto de dados, calcule, para cada ponto de medição, o erro absoluto do PT100:

$$E_{\text{abs}} = |T_{\text{PT100}} - T_{\text{DT670}}|.$$

Adicione os valores calculados ao DataFrame em uma nova coluna.

3. Calcule também o erro relativo percentual do PT100 em relação ao DT-670:

$$E_{\text{rel}} = \frac{|T_{\text{PT100}} - T_{\text{DT670}}|}{T_{\text{DT670}}} \times 100.$$

Adicione os resultados ao DataFrame em uma nova coluna.

4. Determine o erro absoluto médio e o erro relativo médio considerando todos os pontos de medição.
5. Construa um gráfico das temperaturas indicadas pelo DT-670 e pelo PT100 em função do ponto de medição.
6. Construa um gráfico do erro absoluto do PT100 em função da temperatura indicada pelo DT-670.

Analise se o afastamento entre as indicações dos sensores permanece aproximadamente constante ou se apresenta tendência de variação ao longo da faixa de temperatura estudada.

7. Construa um gráfico de dispersão relacionando as temperaturas indicadas pelos dois sensores, utilizando:

$$x = T_{\text{DT670}}$$

e

$$y = T_{\text{PT100}}.$$

8. Ajuste aos dados um modelo de regressão linear da forma:

$$T_{\text{PT100}} = aT_{\text{DT670}} + b,$$

em que a representa o coeficiente angular da reta e b representa o intercepto.

Determine numericamente os valores de a e b .

9. Determine o coeficiente de determinação R^2 associado ao ajuste linear.
10. No mesmo gráfico de dispersão, represente:
 - os dados correspondentes às medições;
 - a reta obtida pela regressão linear;
 - a reta correspondente à condição de concordância ideal,

$$T_{\text{PT100}} = T_{\text{DT670}}.$$

11. Compare a reta de regressão com a condição de concordância ideal

$$T_{\text{PT100}} = T_{\text{DT670}},$$

e interprete os valores obtidos para o coeficiente angular a e para o intercepto b .

12. Calcule, para cada ponto de medição, o resíduo do modelo de regressão linear:

$$r_i = T_{\text{PT100},i} - \hat{T}_{\text{PT100},i},$$

em que $\hat{T}_{\text{PT100},i}$ representa a temperatura estimada pelo modelo de regressão.

Construa um gráfico dos resíduos em função da temperatura indicada pelo DT-670 e analise sua distribuição.

13. A partir dos erros calculados, dos gráficos construídos, do coeficiente de determinação R^2 e da análise dos resíduos, discuta o comportamento das indicações do PT100 em relação ao DT-670 na faixa de temperatura analisada.

Em sua análise, discuta também se um valor de R^2 próximo da unidade é suficiente, isoladamente, para afirmar que existe concordância entre as indicações dos dois sensores.

Gabarito – Exercício 3

1. Importação das bibliotecas e leitura dos dados

O primeiro passo consiste em importar as bibliotecas que serão utilizadas ao longo da análise. Neste exercício serão empregadas principalmente as bibliotecas NumPy, Pandas e Matplotlib.

A biblioteca Pandas será utilizada para a leitura e manipulação dos dados armazenados no arquivo CSV. A biblioteca NumPy será utilizada posteriormente nos cálculos envolvendo

regressão linear e operações numéricas, enquanto a biblioteca Matplotlib será empregada na construção dos gráficos.

O código para importar as bibliotecas é:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
```

Em seguida, o arquivo `criogenia.csv` pode ser carregado utilizando a função `read_csv()` da biblioteca Pandas:

```
# Leitura do arquivo com os dados experimentais simulados
tabela = pd.read_csv("criogenia.csv")

# Visualização dos dados no console
print(tabela)
```

O DataFrame obtido possui três colunas:

- `ponto`: identifica cada ponto de medição;
- `DT670_K`: contém as temperaturas indicadas pelo DT-670, em kelvin;
- `PT100_K`: contém as temperaturas indicadas pelo PT100, em kelvin.

As primeiras linhas do conjunto de dados são, por exemplo,

ponto	DT670_K	PT100_K	
0	1	4.20	4.59
1	2	5.00	5.29
2	3	6.00	6.52
3	4	7.00	7.42
4	5	8.00	8.52

É importante observar que os números mostrados à esquerda não correspondem à coluna `ponto`. Eles representam o índice criado automaticamente pelo Pandas para identificar as linhas do DataFrame.

Assim, na primeira linha,

`ponto = 1,`

enquanto o índice do DataFrame é igual a zero.

Essa distinção será importante posteriormente quando forem realizadas operações de seleção e manipulação dos dados.

2. Cálculo do erro absoluto

O DT-670 foi definido, para este conjunto de dados didáticos, como o sensor de referência. Dessa forma, deseja-se quantificar o afastamento entre a temperatura indicada pelo PT100 e a temperatura correspondente indicada pelo DT-670. Uma primeira maneira de realizar essa comparação consiste no cálculo do **erro absoluto**.

Para cada ponto de medição,

$$E_{\text{abs}} = |T_{\text{PT100}} - T_{\text{DT670}}|.$$

O símbolo de módulo garante que o erro absoluto seja expresso como uma grandeza não negativa. É importante distinguir, portanto, a **diferença entre as indicações**

$$T_{\text{PT100}} - T_{\text{DT670}}$$

do **erro absoluto**

$$|T_{\text{PT100}} - T_{\text{DT670}}|.$$

A primeira expressão preserva o sinal da diferença, enquanto a segunda quantifica apenas a magnitude do afastamento entre as duas indicações.

Cálculo manual para o primeiro ponto

No primeiro ponto de medição, os valores são:

$$T_{\text{DT670}} = 4,20 \text{ K}$$

e

$$T_{\text{PT100}} = 4,59 \text{ K}.$$

Aplicando a expressão do erro absoluto:

$$E_{\text{abs},1} = |4,59 - 4,20|.$$

Portanto,

$$E_{\text{abs},1} = |0,39|$$

e, conseqüentemente,

$$\boxed{E_{\text{abs},1} = 0,39 \text{ K}}$$

Cálculo manual para o segundo ponto

Para o segundo ponto:

$$T_{\text{DT670}} = 5,00 \text{ K}$$

e

$$T_{\text{PT100}} = 5,29 \text{ K.}$$

Logo,

$$E_{\text{abs},2} = |5,29 - 5,00|$$

e

$$E_{\text{abs},2} = 0,29 \text{ K}$$

O mesmo procedimento poderia ser repetido manualmente para todos os 21 pontos de medição. Entretanto, uma das vantagens da computação científica consiste justamente em aplicar a mesma operação simultaneamente a todos os elementos de uma série de dados.

Cálculo utilizando Python

No Pandas, as colunas de um DataFrame podem participar diretamente de operações matemáticas. Assim, a diferença entre as indicações dos dois sensores pode ser calculada por:

```
tabela["PT100_K"] - tabela["DT670_K"]
```

Como o objetivo é determinar o erro absoluto, deve-se calcular o módulo dessa diferença. Para isso, pode-se utilizar a função `np.abs()` da biblioteca NumPy:

```
# Cálculo do erro absoluto em cada ponto de medição
tabela["erro_abs_K"] = np.abs(
    tabela["PT100_K"] - tabela["DT670_K"]
)
```

A expressão

```
tabela["PT100_K"] - tabela["DT670_K"]
```

é aplicada elemento a elemento. Isso significa que o Python realiza automaticamente operações equivalentes a:

$$4,59 - 4,20,$$

$$5,29 - 5,00,$$

$$6,52 - 6,00,$$

e assim sucessivamente até o último ponto de medição.

Em seguida, a função

```
np.abs(...)
```

calcula o valor absoluto de cada resultado.

Os valores obtidos são armazenados em uma nova coluna do DataFrame, denominada

```
erro_abs_K
```

Para visualizar o resultado, pode-se utilizar:

```
# Visualização das temperaturas e do erro absoluto
print(
    tabela[
        ["ponto", "DT670_K", "PT100_K", "erro_abs_K"]
    ]
)
```

As primeiras linhas passam a apresentar a seguinte estrutura:

ponto	DT670_K	PT100_K	erro_abs_K	
0	1	4.20	4.59	0.39
1	2	5.00	5.29	0.29
2	3	6.00	6.52	0.52
3	4	7.00	7.42	0.42
4	5	8.00	8.52	0.52

Pode-se verificar que os resultados calculados pelo Python para os dois primeiros pontos coincidem com aqueles obtidos anteriormente por meio do cálculo manual:

$$E_{\text{abs},1} = 0,39 \text{ K}$$

e

$$E_{\text{abs},2} = 0,29 \text{ K}.$$

Essa comparação é útil porque permite verificar a correspondência entre a formulação matemática do problema e sua implementação computacional.

Neste estágio, o erro absoluto informa **quanto**, em kelvin, a indicação do PT100 se afasta da indicação utilizada como referência. Entretanto, ele ainda não informa se esse afastamento é grande ou pequeno quando comparado à magnitude da temperatura medida.

Essa questão será analisada por meio do erro relativo percentual.

3. Cálculo do erro relativo percentual

O erro absoluto calculado anteriormente informa a magnitude da diferença entre a indicação do PT100 e a indicação do DT-670, expressa diretamente em kelvin. Entretanto, analisar apenas o erro absoluto pode não ser suficiente para avaliar a importância desse afastamento.

Por exemplo, um erro de 0,50 K pode representar uma parcela significativa de uma temperatura de 5 K, mas uma parcela muito menor de uma temperatura de 50 K. Para levar em consideração a magnitude da temperatura utilizada como referência, pode-se calcular o **erro relativo percentual**.

Neste exercício, considerando o DT-670 como referência didática, o erro relativo percentual é definido por:

$$E_{\text{rel}} = \frac{|T_{\text{PT100}} - T_{\text{DT670}}|}{T_{\text{DT670}}} \times 100.$$

Como o numerador corresponde exatamente ao erro absoluto calculado anteriormente, a expressão também pode ser escrita como:

$$E_{\text{rel}} = \frac{E_{\text{abs}}}{T_{\text{DT670}}} \times 100$$

O resultado é expresso em porcentagem e representa o afastamento entre as indicações dos sensores em relação à magnitude da temperatura adotada como referência.

Cálculo manual para o primeiro ponto

No primeiro ponto de medição:

$$T_{\text{DT670}} = 4,20 \text{ K}$$

e

$$T_{\text{PT100}} = 4,59 \text{ K}.$$

O erro absoluto já foi determinado anteriormente:

$$E_{\text{abs},1} = 0,39 \text{ K}.$$

Portanto, o erro relativo percentual é:

$$E_{\text{rel},1} = \frac{0,39}{4,20} \times 100.$$

Realizando o cálculo:

$$E_{\text{rel},1} = 0,092857 \times 100$$

e, consequentemente,

$$E_{\text{rel},1} \approx 9,29\%$$

Assim, embora a diferença entre as indicações seja de apenas 0,39 K, esse afastamento corresponde a aproximadamente 9,29% da temperatura indicada pelo DT-670.

Cálculo manual para o segundo ponto

No segundo ponto:

$$T_{\text{DT670}} = 5,00 \text{ K},$$

$$T_{\text{PT100}} = 5,29 \text{ K}$$

e

$$E_{\text{abs},2} = 0,29 \text{ K}.$$

Logo,

$$E_{\text{rel},2} = \frac{0,29}{5,00} \times 100.$$

Portanto,

$$E_{\text{rel},2} = 5,80\%$$

Observe que o primeiro ponto apresenta erro absoluto de 0,39 K e erro relativo de aproximadamente 9,29%, enquanto o segundo apresenta erro absoluto de 0,29 K e erro relativo de 5,80%. Essa comparação mostra que o erro relativo incorpora não apenas a diferença entre as indicações, mas também a magnitude do valor utilizado como referência.

Cálculo utilizando Python

Como a coluna `erro_abs_K` já foi criada no DataFrame, ela pode ser utilizada diretamente no cálculo do erro relativo percentual:

```
# 3. Cálculo do erro relativo percentual
```

```
tabela["erro_rel_porcent"] = (
    tabela["erro_abs_K"] / tabela["DT670_K"]
) * 100
```

A operação é realizada elemento a elemento. Para cada linha do DataFrame, o Python divide o erro absoluto pela temperatura correspondente indicada pelo DT-670 e multiplica o resultado por 100.

Para visualizar as novas informações:

```
# Visualização dos erros absoluto e relativo.

# Define o número de casas decimais exibidas pelo Pandas
pd.options.display.float_format = "{:.2f}".format

print(
    tabela[
        [
            "ponto",
            "DT670_K",
            "PT100_K",
            "erro_abs_K",
            "erro_rel_porcent"
        ]
    ]
)
```

As primeiras linhas apresentam resultados equivalentes a:

	ponto	DT670_K	PT100_K	erro_abs_K	erro_rel_porcent
0	1	4.20	4.59	0.39	9.29
1	2	5.00	5.29	0.29	5.80
2	3	6.00	6.52	0.52	8.67
3	4	7.00	7.42	0.42	6.00
4	5	8.00	8.52	0.52	6.50

Os valores calculados pelo Python para os dois primeiros pontos coincidem com aqueles obtidos manualmente:

$$E_{\text{rel},1} \approx 9,29\%$$

e

$$E_{\text{rel},2} = 5,80\%.$$

Portanto, o DataFrame passa a reunir, em uma única estrutura, as temperaturas originais e os indicadores de erro calculados para cada ponto de medição.

É importante observar que a definição

```
pd.options.display.float_format = "{:.2f}".format
```

altera apenas a forma como os valores numéricos são apresentados no console. Os valores armazenados no DataFrame permanecem com sua precisão numérica original.

Essa distinção é importante porque arredondamentos realizados antes das etapas seguintes de cálculo podem produzir pequenas diferenças nos resultados finais. Por esse motivo, neste exercício, os valores são mantidos com sua precisão original para os cálculos e arredondados apenas para fins de apresentação.

A figura 5 mostra diferentes formas de visualizar um DataFrame no console.

Diferentes formas de visualizar um DataFrame no console

O comando print() pode ser utilizado de diferentes maneiras, dependendo do que se deseja visualizar. Abaixo são apresentadas algumas opções comuns.

1. DataFrame completo
Mostra todas as colunas e todas as linhas (ou as primeiras e últimas, se houver muitas linhas).


```
In [1]:  
print(tabela)
```

Saída no console:

	ponto	DT670_K	PT100_K	erro_abs_K	erro_rel_porcent
0	1	4.20	4.59	0.39	9.29
1	2	5.00	5.29	0.29	5.80
2	3	6.00	6.52	0.52	8.67
3	4	7.00	7.42	0.42	6.00
4	5	8.00	8.52	0.52	6.50
...	...	...	...	...	...
19	20	45.00	48.39	3.39	7.53
20	21	50.00	53.75	3.75	7.50

Observação:
Para DataFrames muito grandes, o Pandas mostra apenas as primeiras e últimas linhas.

2. Apenas algumas colunas
Mostra somente as colunas selecionadas (todas as linhas).


```
In [2]:  
print(  
    tabela[  
        "ponto",  
        "DT670_K",  
        "PT100_K",  
        "erro_abs_K",  
        "erro_rel_porcent"  
    ]  
)
```

Saída no console:

	ponto	DT670_K	PT100_K	erro_abs_K	erro_rel_porcent
0	1	4.20	4.59	0.39	9.29
1	2	5.00	5.29	0.29	5.80
2	3	6.00	6.52	0.52	8.67
3	4	7.00	7.42	0.42	6.00
4	5	8.00	8.52	0.52	6.50
...	...	...	...	...	...
19	20	45.00	48.39	3.39	7.53
20	21	50.00	53.75	3.75	7.50

Vantagem:
permite focar apenas nas colunas de interesse.

3. Apenas as primeiras linhas
Mostra um número limitado de linhas (nesse exemplo, 5).


```
In [3]:  
print(tabela.head(5))
```

Saída no console:

	ponto	DT670_K	PT100_K	erro_abs_K	erro_rel_porcent
0	1	4.20	4.59	0.39	9.29
1	2	5.00	5.29	0.29	5.80
2	3	6.00	6.52	0.52	8.67
3	4	7.00	7.42	0.42	6.00
4	5	8.00	8.52	0.52	6.50

4. Apenas as últimas linhas
Mostra as últimas linhas (nesse exemplo, 5).


```
In [4]:  
print(tabela.tail(5))
```

Saída no console:

	ponto	DT670_K	PT100_K	erro_abs_K	erro_rel_porcent
16	17	40.00	43.10	3.10	7.75
17	18	42.00	45.26	3.26	7.76
18	19	44.00	47.33	3.33	7.57
19	20	45.00	48.39	3.39	7.53
20	21	50.00	53.75	3.75	7.50

5. Controle do número de casas decimais

a) Arredondar apenas na visualização
Mostra os valores com duas casas decimais, sem alterar os dados armazenados.


```
In [5]:  
print(  
    tabela[  
        ["ponto", "DT670_K", "PT100_K",  
         "erro_abs_K", "erro_rel_porcent"]  
    ].round(2)  
)
```

Saída no console:

	ponto	DT670_K	PT100_K	erro_abs_K	erro_rel_porcent
0	1	4.20	4.59	0.39	9.29
1	2	5.00	5.29	0.29	5.80
2	3	6.00	6.52	0.52	8.67
3	4	7.00	7.42	0.42	6.00
4	5	8.00	8.52	0.52	6.50
...	...	...	...	...	...
19	20	45.00	48.39	3.39	7.53
20	21	50.00	53.75	3.75	7.50

b) Definir o formato global do Pandas
Afeta todas as colunas numéricas exibidas.


```
In [6]:  
pd.options.display.float_format = "{:.2f}".format  
print(tabela)
```

Observação:
O formato de exibição não altera os valores usados nos cálculos. Para manter a precisão, arredonde apenas na visualização (como em 5a) ou defina o formato global.

Figura 5: Diferentes formas de visualizar um DataFrame no console utilizando Pandas.

4. Determinação dos erros médios

Os erros calculados anteriormente permitem analisar individualmente cada ponto de medição. Entretanto, também é útil obter indicadores que representem, de forma global, o comportamento do conjunto de dados.

Para isso, serão calculados:

- o erro absoluto médio;
- o erro relativo percentual médio.

31

Erro absoluto médio

Para um conjunto contendo n pontos de medição, o erro absoluto médio pode ser definido como:

$$\overline{E}_{\text{abs}} = \frac{1}{n} \sum_{i=1}^n E_{\text{abs},i}$$

Neste exercício existem:

$$n = 21$$

pontos de medição.

Portanto,

$$\overline{E}_{\text{abs}} = \frac{E_{\text{abs},1} + E_{\text{abs},2} + \cdots + E_{\text{abs},21}}{21}.$$

Para compreender o cálculo, os erros absolutos obtidos a partir dos dados são:

$$E_{\text{abs},1} = 0,39 \text{ K},$$

$$E_{\text{abs},2} = 0,29 \text{ K},$$

$$E_{\text{abs},3} = 0,52 \text{ K},$$

$$\vdots$$

$$E_{\text{abs},21} = 3,75 \text{ K}.$$

A soma dos 21 erros absolutos é:

$$\sum_{i=1}^{21} E_{\text{abs},i} = 32,36 \text{ K}.$$

Consequentemente,

$$\overline{E}_{\text{abs}} = \frac{32,36}{21}.$$

Logo,

$$\overline{E}_{\text{abs}} \approx 1,541 \text{ K}$$

Esse valor representa a magnitude média do afastamento entre as indicações do PT100 e do DT-670 para o conjunto de dados analisado.

Erro relativo percentual médio

De maneira semelhante, o erro relativo percentual médio é calculado por:

$$\overline{E}_{\text{rel}} = \frac{1}{n} \sum_{i=1}^n E_{\text{rel},i}$$

Portanto,

$$\overline{E}_{\text{rel}} = \frac{E_{\text{rel},1} + E_{\text{rel},2} + \cdots + E_{\text{rel},21}}{21}.$$

Para os dados analisados, obtém-se:

$$\overline{E}_{\text{rel}} \approx 6,52\%$$

Esse resultado indica que, considerando todos os pontos analisados, a magnitude média do afastamento percentual das indicações do PT100 em relação às indicações adotadas como referência é de aproximadamente 6,52%.

Cálculo utilizando Python

Como os erros de cada ponto já estão armazenados no DataFrame, os valores médios podem ser determinados diretamente utilizando o método `mean()` do Pandas:

```
# Cálculo do erro absoluto médio
erro_abs_medio = tabela["erro_abs_K"].mean()

# Cálculo do erro relativo percentual médio
erro_rel_medio = tabela["erro_rel_percent"].mean()

# Apresentação dos resultados
print("-----")
print("Erros médios")
print("-----")
print(f"Erro absoluto médio = {erro_abs_medio:.4f} K")
print(f"Erro relativo médio = {erro_rel_medio:.4f} %")
```

A saída será:

```
-----
Erros médios
-----
Erro absoluto médio = 1.5410 K
Erro relativo médio = 6.5232 %
```

Os resultados computacionais confirmam os valores determinados a partir das expressões matemáticas:

$$\overline{E}_{\text{abs}} = 1,5410 \text{ K}$$

e

$$\overline{E}_{\text{rel}} = 6,5232\%$$

Interpretação dos resultados

Os dois indicadores fornecem informações complementares.

O erro absoluto médio,

$$\overline{E}_{\text{abs}} = 1,5410 \text{ K},$$

expressa o afastamento médio entre as indicações dos sensores diretamente na unidade da grandeza medida.

Já o erro relativo médio,

$$\overline{E}_{\text{rel}} = 6,5232\%,$$

expressa esse afastamento em relação à magnitude das temperaturas utilizadas como referência.

É importante observar que esses valores médios resumem o comportamento global do conjunto de dados, mas não mostram como o erro se distribui ao longo da faixa de temperatura. Dois conjuntos de dados diferentes poderiam, por exemplo, apresentar o mesmo erro absoluto médio e, ainda assim, possuir distribuições de erro completamente diferentes. Por essa razão, a análise não deve terminar nos valores médios.

Nos próximos passos, os dados e os erros serão representados graficamente, permitindo investigar como o afastamento entre as indicações dos sensores evolui ao longo da faixa de temperatura estudada.

5. Comparação gráfica das temperaturas

Até este ponto, a comparação entre as indicações do DT-670 e do PT100 foi realizada numericamente por meio dos erros absoluto e relativo.

Entretanto, a representação gráfica permite observar de maneira mais direta como as indicações dos dois sensores evoluem ao longo dos pontos de medição.

Neste primeiro gráfico, serão representadas:

- a temperatura indicada pelo DT-670;
- a temperatura indicada pelo PT100.

O eixo horizontal será formado pela variável **ponto**, enquanto o eixo vertical representará a temperatura, em kelvin.

Matematicamente, serão representados os conjuntos de pontos:

$$(p_i, T_{\text{DT670},i})$$

e

$$(p_i, T_{\text{PT100},i}),$$

em que p_i representa o número correspondente ao ponto de medição.

Construção do gráfico utilizando Python

O gráfico pode ser construído utilizando a biblioteca Matplotlib:

```
# Criação da figura
plt.figure(figsize=(10, 6))

# Temperaturas indicadas pelo DT-670
plt.plot(
    tabela["ponto"],
    tabela["DT670_K"],
    color="black",
    linestyle="-",
    marker="o",
    label="DT-670"
)

# Temperaturas indicadas pelo PT100
plt.plot(
    tabela["ponto"],
    tabela["PT100_K"],
    color="black",
    linestyle="--",
    marker="s",
    label="PT100"
)

# Identificação dos eixos
plt.xlabel("Ponto de medição")
plt.ylabel("Temperatura (K)")

# Título do gráfico
plt.title("Comparação entre as indicações do DT-670 e do PT100")
```

```
# Grade e legenda
plt.grid(True)
plt.legend()

# Ajuste automático do espaçamento
plt.tight_layout()

# Exibição do gráfico
plt.show()
```

O gráfico da figura 6 mostra a comparação entre as indicações DT-670 e do PT100 ao longo dos pontos de medição.




Figura 6: Comparação entre as temperaturas indicadas pelo DT-670 e pelo PT100 ao longo dos pontos de medição.

Embora as duas curvas sejam representadas em preto, elas podem ser diferenciadas pelo estilo das linhas e pelos marcadores utilizados.

Para o DT-670 foram empregados:

- linha contínua;
- marcador circular.

Para o PT100 foram empregados:

- linha tracejada;
- marcador quadrado.

Essa forma de representação permite que o gráfico permaneça legível mesmo quando impresso em escala de cinza.

Interpretação do gráfico

As duas séries apresentam comportamento crescente ao longo dos pontos de medição, o que é esperado, uma vez que os dados correspondem a diferentes temperaturas distribuídas aproximadamente entre 4 K e 50 K. Entretanto, observa-se que as curvas não permanecem perfeitamente sobrepostas. Para os dados analisados, as indicações do PT100 são superiores às indicações adotadas como referência em todos os pontos de medição. Nos primeiros pontos, a separação entre as curvas é relativamente pequena. À medida que a temperatura aumenta, entretanto, o afastamento visual entre elas torna-se progressivamente mais evidente.

Por exemplo, no primeiro ponto:

$$T_{DT670} = 4,20 \text{ K}$$

e

$$T_{PT100} = 4,59 \text{ K},$$

resultando em uma diferença de:

$$0,39 \text{ K}.$$

No último ponto:

$$T_{DT670} = 50,00 \text{ K}$$

e

$$T_{PT100} = 53,75 \text{ K},$$

resultando em:

$$3,75 \text{ K}.$$

Portanto, uma primeira inspeção gráfica sugere que o afastamento entre as indicações dos sensores não permanece constante ao longo da faixa de temperatura. Essa observação pode ser investigada de maneira mais direta construindo um gráfico específico para o erro absoluto.

6. Análise gráfica do erro absoluto

No item anterior, o afastamento entre as curvas foi identificado visualmente. Entretanto, como as duas temperaturas estão representadas no mesmo gráfico, a magnitude do erro não é mostrada diretamente. Para investigar especificamente esse comportamento, será construído um gráfico relacionando o erro absoluto do PT100 com a temperatura indicada pelo DT-670.

Assim, serão representados os pares:

$$(T_{\text{DT670},i}, E_{\text{abs},i}).$$

O eixo horizontal representará:

$$T_{\text{DT670}},$$

enquanto o eixo vertical representará:

$$E_{\text{abs}}.$$

Alguns pontos antes da construção do gráfico

Para compreender o comportamento esperado, podem ser observados alguns valores distribuídos ao longo da faixa de temperatura.

Para:

$$T_{\text{DT670}} = 4,20 \text{ K},$$

tem-se:

$$E_{\text{abs}} = 0,39 \text{ K}.$$

Para:

$$T_{\text{DT670}} = 20,00 \text{ K},$$

tem-se:

$$E_{\text{abs}} = |21,09 - 20,00| = 1,09 \text{ K}.$$

Para:

$$T_{\text{DT670}} = 30,00 \text{ K},$$

tem-se:

$$E_{\text{abs}} = |31,83 - 30,00| = 1,83 \text{ K}.$$

Para:

$$T_{\text{DT670}} = 40,00 \text{ K},$$

tem-se:

$$E_{\text{abs}} = |42,64 - 40,00| = 2,64 \text{ K}.$$

Finalmente, para:

$$T_{\text{DT670}} = 50,00 \text{ K},$$

obtem-se:

$$E_{\text{abs}} = |53,75 - 50,00| = 3,75 \text{ K}.$$

Organizando apenas esses pontos para facilitar a comparação:

$T_{\text{DT670}} \text{ (K)}$	$E_{\text{abs}} \text{ (K)}$
4,20	0,39
20,00	1,09
30,00	1,83
40,00	2,64
50,00	3,75

Mesmo antes da construção do gráfico, esses valores indicam que o erro absoluto não permanece constante ao longo da faixa analisada.

Construção do gráfico utilizando Python

Como a coluna `erro_abs_K` já foi calculada anteriormente, o gráfico pode ser construído diretamente:

```
# Criação da figura
plt.figure(figsize=(10, 6))

# Erro absoluto em função da temperatura de referência
plt.plot(
    tabela["DT670_K"],
    tabela["erro_abs_K"],
    color="black",
    linestyle="-",
    marker="o"
)

# Identificação dos eixos
plt.xlabel("Temperatura indicada pelo DT-670 (K)")
plt.ylabel("Erro absoluto (K)")

# Título do gráfico
plt.title("Erro absoluto em função da temperatura indicada pelo DT-670")
```

```
# Grade
plt.grid(True)

# Ajuste automático do espaçamento
plt.tight_layout()

# Exibição do gráfico
plt.show()
```

A figura 7 mostra o gráfico do erro absoluto do sensor PT100 em relação ao DT-670.




Figura 7: Erro absoluto em função da temperatura indicada pelo DT-670.

Análise do comportamento do erro

O gráfico mostra que o erro absoluto não permanece aproximadamente constante ao longo da faixa de temperatura. Apesar de existirem pequenas variações entre pontos consecutivos, observa-se uma tendência geral de aumento de E_{abs} à medida que a temperatura indicada pelo DT-670 aumenta.

Esse comportamento pode ser expresso qualitativamente como:

$$T_{\text{DT670}} \uparrow \quad \Rightarrow \quad E_{\text{abs}} \uparrow$$

para o conjunto de dados analisado.

É importante observar que essa expressão representa uma **tendência observada nos dados** e não uma relação física universal para os sensores considerados.

Por exemplo, entre os dois primeiros pontos ocorre:

$$E_{\text{abs},1} = 0,39 \text{ K}$$

e

$$E_{\text{abs},2} = 0,29 \text{ K}.$$

Portanto, não se pode afirmar que o erro aumenta obrigatoriamente em cada novo ponto de medição. O que se observa é uma tendência global de crescimento do afastamento.

Erro constante e erro dependente da temperatura

Essa análise permite estabelecer uma distinção importante. Se o afastamento entre as indicações permanecesse aproximadamente constante, seria esperado um comportamento semelhante a:

$$E_{\text{abs}} \approx \text{constante}.$$

Nesse caso, o gráfico do erro absoluto em função da temperatura seria aproximadamente horizontal. Entretanto, não é isso que ocorre no conjunto de dados analisado.

Os valores passam de aproximadamente:

$$0,39 \text{ K}$$

na região de 4,20 K para:

$$3,75 \text{ K}$$

em 50,00 K.

Assim, os dados indicam que o afastamento entre as indicações possui dependência com a temperatura dentro da faixa estudada.

Interpretação de engenharia

A análise gráfica fornece uma informação que o erro absoluto médio, isoladamente, não poderia revelar.

Anteriormente foi obtido:

$$\overline{E}_{\text{abs}} = 1,5410 \text{ K}.$$

Esse valor é útil como indicador global, mas não significa que o PT100 apresente um afastamento de aproximadamente 1,54 K em todos os pontos. Na realidade, o erro varia ao longo da faixa analisada.

Portanto, ao avaliar dados provenientes de instrumentos de medição, não é suficiente analisar apenas uma medida média de erro. Também é importante investigar se existe alguma relação entre o erro e a própria grandeza que está sendo medida. Neste conjunto de dados, essa relação visual sugere a existência de um componente sistemático no afastamento entre as indicações dos sensores. Entretanto, o gráfico do erro absoluto não permite,

sozinho, estabelecer completamente a relação matemática existente entre as duas séries de temperatura.

Para investigar essa relação, o próximo passo consiste em representar diretamente:

$$T_{\text{PT100}} \quad \text{em função de} \quad T_{\text{DT670}},$$

por meio de um gráfico de dispersão.

7. Gráfico de dispersão entre as indicações dos sensores

Nos gráficos anteriores, as temperaturas foram representadas em função do ponto de medição e o erro absoluto foi analisado em função da temperatura indicada pelo DT-670. Essas representações permitiram observar que existe um afastamento entre as indicações dos sensores e que esse afastamento apresenta uma tendência de crescimento ao longo da faixa de temperatura analisada. Entretanto, para investigar diretamente a relação existente entre as indicações dos dois sensores, é conveniente construir um **gráfico de dispersão**.

Nesse tipo de gráfico, cada ponto experimental é representado por um par ordenado:

$$(x_i, y_i).$$

Neste exercício, será adotado:

$$x_i = T_{\text{DT670},i}$$

e

$$y_i = T_{\text{PT100},i}.$$

Portanto, cada ponto do gráfico terá a forma:

$$\boxed{(T_{\text{DT670},i}, T_{\text{PT100},i})}$$

Isso significa que o eixo horizontal representa a temperatura indicada pelo DT-670, enquanto o eixo vertical representa a temperatura indicada pelo PT100.

Construção manual de alguns pares ordenados

Para o primeiro ponto de medição:

$$T_{\text{DT670}} = 4,20 \text{ K}$$

e

$$T_{\text{PT100}} = 4,59 \text{ K}.$$

Portanto, o primeiro ponto do gráfico será:

$$(4,20; 4,59).$$

Para o segundo ponto:

$$(5,00; 5,29).$$

Para o terceiro:

$$(6,00; 6,52).$$

No último ponto de medição:

$$(50,00; 53,75).$$

Assim, o gráfico de dispersão não utiliza o número do ponto de medição como variável independente. Ele relaciona diretamente as indicações fornecidas pelos dois sensores.

O que se espera observar

Se as indicações dos dois sensores apresentassem concordância perfeita em todos os pontos, teríamos:

$$T_{\text{PT100}} = T_{\text{DT670}}.$$

Nesse caso, todos os pares ordenados teriam a forma:

$$(T, T),$$

como, por exemplo,

$$(10, 10), \quad (20, 20), \quad (30, 30).$$

Geometricamente, esses pontos estariam localizados sobre uma reta com coeficiente angular igual a 1 e intercepto igual a zero:

$$\boxed{y = x}$$

ou, utilizando as variáveis do problema,

$$\boxed{T_{\text{PT100}} = T_{\text{DT670}}}$$

Essa reta será posteriormente utilizada como referência para avaliar graficamente a concordância entre as indicações.

Construção do gráfico utilizando Python

O gráfico de dispersão pode ser construído utilizando a função `scatter()` da biblioteca Matplotlib:

```
# Criação da figura
plt.figure(figsize=(8, 6))

# Gráfico de dispersão
plt.scatter(
    tabela["DT670_K"],
    tabela["PT100_K"],
    color="black",
    marker="o",
    label="Dados"
)

# Identificação dos eixos
plt.xlabel("Temperatura indicada pelo DT-670 (K)")
plt.ylabel("Temperatura indicada pelo PT100 (K)")

# Título do gráfico
plt.title("Relação entre as indicações do DT-670 e do PT100")

# Grade e legenda
plt.grid(True)
plt.legend()

# Ajuste automático do espaçamento
plt.tight_layout()

# Exibição do gráfico
plt.show()
```

A figura 8 mostra o gráfico da relação entre as indicações do DT-670 e do PT100.




Figura 8: Relação entre as temperaturas indicadas pelo DT-670 e pelo PT100.

Interpretação inicial

O gráfico mostra que os pontos apresentam uma tendência aproximadamente linear. À medida que a temperatura indicada pelo DT-670 aumenta, a temperatura indicada pelo PT100 também aumenta.

Pode-se representar qualitativamente esse comportamento por:

$$T_{\text{DT670}} \uparrow \implies T_{\text{PT100}} \uparrow .$$

Entretanto, identificar visualmente uma tendência aproximadamente linear não é suficiente para determinar quantitativamente a relação entre as duas variáveis. Para isso, será ajustado um modelo matemático aos dados.

8. Ajuste de um modelo de regressão linear

O gráfico de dispersão sugere que a relação entre as indicações dos dois sensores pode ser aproximada, dentro da faixa estudada, por uma função linear.

Será considerado o modelo:

$$T_{\text{PT100}} = aT_{\text{DT670}} + b$$

ou, de maneira geral,

$$y = ax + b.$$

Nesse modelo:

- x representa a temperatura indicada pelo DT-670;
- y representa a temperatura indicada pelo PT100;
- a representa o coeficiente angular da reta;
- b representa o intercepto da reta com o eixo vertical.

Significado do coeficiente angular

O coeficiente angular a determina quanto o valor estimado de y varia quando x aumenta uma unidade.

Para uma função

$$y = ax + b,$$

tem-se:

$$a = \frac{\Delta y}{\Delta x}.$$

No contexto deste exercício, o coeficiente angular descreve como a indicação do PT100 varia em relação à indicação do DT-670 ao longo da faixa analisada. Se houvesse concordância ideal entre as indicações, seria esperado:

$$a = 1.$$

Nesse caso, um aumento de 1 K na indicação do DT-670 estaria associado a um aumento de 1 K na indicação do PT100.

Significado do intercepto

O parâmetro b corresponde ao valor previsto para y quando:

$$x = 0.$$

Matematicamente,

$$y(0) = b.$$

Na condição ideal de concordância entre as indicações:

$$b = 0.$$

Assim, a condição ideal corresponde simultaneamente a:

$$a = 1$$

e

$$b = 0.$$

Portanto:

$$y = 1x + 0$$

e, conseqüentemente,

$$\boxed{y = x}.$$

É importante observar que, neste exercício, o valor de b deve ser interpretado como um parâmetro matemático do modelo ajustado na faixa analisada. Não se deve extrapolar automaticamente o modelo até 0 K nem atribuir ao intercepto, isoladamente, o significado de uma medição física realizada nessa temperatura.

Por que não utilizar apenas dois pontos?

Uma reta pode ser determinada exatamente a partir de dois pontos. Por exemplo, utilizando apenas o primeiro e o último ponto do conjunto, poderíamos calcular:

$$a = \frac{53,75 - 4,59}{50,00 - 4,20}.$$

Assim:

$$a = \frac{49,16}{45,80}$$

e:

$$a \approx 1,0734.$$

Conhecendo a , poderíamos utilizar um dos pontos para calcular b :

$$y = ax + b.$$

Utilizando o primeiro ponto:

$$4,59 = 1,0734(4,20) + b.$$

Portanto:

$$b = 4,59 - 1,0734(4,20),$$

resultando aproximadamente em:

$$b \approx 0,082.$$

Essa reta passa exatamente pelos dois pontos escolhidos.

Entretanto, o conjunto experimental contém 21 pontos, e os demais pontos não estão perfeitamente alinhados sobre uma única reta. Assim, escolher apenas dois pontos significaria ignorar grande parte das informações disponíveis. O objetivo da regressão linear é diferente: deseja-se determinar uma reta que represente, da melhor maneira possível segundo um critério definido, o conjunto completo de observações.

Valor observado e valor estimado

Para cada valor de temperatura indicado pelo DT-670 existe um valor observado do PT100:

$$T_{\text{PT100},i}.$$

Quando uma reta é ajustada aos dados, o modelo fornece também um valor estimado:

$$\hat{T}_{\text{PT100},i}.$$

O símbolo “chapéu” indica que esse valor não corresponde necessariamente à observação experimental, mas ao valor calculado pelo modelo.

Para o modelo linear:

$$\boxed{\hat{T}_{\text{PT100},i} = aT_{\text{DT670},i} + b}$$

Em geral, devido à dispersão dos dados:

$$T_{\text{PT100},i} \neq \hat{T}_{\text{PT100},i}.$$

A diferença entre o valor observado e o valor estimado será chamada de **resíduo**:

$$r_i = T_{\text{PT100},i} - \hat{T}_{\text{PT100},i}.$$

Os resíduos serão analisados detalhadamente posteriormente.

Critério dos mínimos quadrados

Para determinar a reta de regressão, é necessário estabelecer um critério para escolher os valores de a e b .

Um dos critérios mais utilizados é o método dos **mínimos quadrados**.

Para cada ponto, o resíduo é:

$$r_i = T_{\text{PT100},i} - (aT_{\text{DT670},i} + b).$$

Se simplesmente somássemos os resíduos,

$$\sum_{i=1}^n r_i,$$

valores positivos e negativos poderiam se cancelar. Por isso, utiliza-se o quadrado de cada resíduo:

$$r_i^2.$$

A soma dos quadrados dos resíduos é:

$$S = \sum_{i=1}^n r_i^2.$$

Substituindo a expressão do resíduo:

$$S = \sum_{i=1}^n [T_{\text{PT100},i} - (aT_{\text{DT670},i} + b)]^2$$

O método dos mínimos quadrados procura os valores de a e b que tornam essa soma tão pequena quanto possível.

Assim:

$$a, b \longrightarrow \min S$$

Em outras palavras, procura-se a reta que minimiza globalmente os quadrados das diferenças verticais entre os valores observados e os valores estimados pelo modelo.

Determinação dos coeficientes

Para uma regressão linear simples, os coeficientes também podem ser calculados pelas expressões:

$$a = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

e

$$b = \bar{y} - a\bar{x}$$

em que:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

e

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i.$$

Neste exercício:

$$x_i = T_{\text{DT670},i}$$

e

$$y_i = T_{\text{PT100},i}.$$

Portanto, essas expressões utilizam todos os 21 pontos do conjunto de dados para determinar os coeficientes da reta.

Cálculo utilizando Python

A biblioteca NumPy possui a função `polyfit()`, que permite ajustar um polinômio aos dados utilizando o método dos mínimos quadrados. Como o modelo desejado é uma reta, utiliza-se um polinômio de grau 1:

```
# Variável independente
x = tabela["DT670_K"]

# Variável dependente
y = tabela["PT100_K"]

# Ajuste da regressão linear
a, b = np.polyfit(x, y, 1)

# Apresentação dos coeficientes
print("-----")
print("Regressão linear")
print("-----")
print(f"Coeficiente angular a = {a:.6f}")
print(f"Intercepto b = {b:.6f} K")
```

Saida numérica:

```
-----
Regressão linear
-----
Coeficiente angular a = 1.070828
Intercepto a = -0.125876 K
```

Na instrução:

```
a, b = np.polyfit(x, y, 1)
```

o valor 1 informa ao NumPy que deve ser ajustado um polinômio de primeiro grau:

$$y = ax + b.$$

Para o conjunto de dados analisado, são obtidos aproximadamente:

$$a = 1,070828$$

e

$$b = -0,125876 \text{ K}$$

Portanto, o modelo de regressão linear pode ser escrito como:

$$\hat{T}_{\text{PT100}} = 1,070828 T_{\text{DT670}} - 0,125876$$

ou, utilizando quatro casas decimais:

$$\hat{T}_{\text{PT100}} = 1,0708 T_{\text{DT670}} - 0,1259$$

Cálculo das temperaturas estimadas pelo modelo

Depois de determinar a e b , é possível calcular a temperatura prevista pela reta para cada valor de T_{DT670} .

Utilizando:

$$\hat{T}_{\text{PT100}} = a T_{\text{DT670}} + b,$$

pode-se criar uma nova coluna no DataFrame:

```
# Temperatura estimada pelo modelo de regressão
tabela["PT100_estimado_K"] = (
a * tabela["DT670_K"] + b
)

# Visualização dos valores observados e estimados
print(
tabela[
[
"ponto",
"DT670_K",
```

```

"PT100_K",
"PT100_estimado_K"
]
]
)

```

Tabela de dados obtida na simulação.

	ponto	DT670_K	PT100_K	PT100_K_estimado_K
0	1	4.20	4.59	4.62
1	2	5.00	5.29	5.48
2	3	6.00	6.52	6.55
3	4	7.00	7.42	7.62
4	5	8.00	8.52	8.69

Para compreender o significado dessa operação, considere o primeiro ponto.

Para:

$$T_{\text{DT670}} = 4,20 \text{ K},$$

o modelo fornece:

$$\hat{T}_{\text{PT100}} = 1,070828(4,20) - 0,125876.$$

Logo:

$$\hat{T}_{\text{PT100}} \approx 4,372 \text{ K}.$$

Entretanto, o valor presente no conjunto de dados é:

$$T_{\text{PT100}} = 4,59 \text{ K}.$$

Portanto:

$$T_{\text{PT100}} \neq \hat{T}_{\text{PT100}}.$$

Isso não representa um erro do procedimento de regressão.

A reta não foi construída para passar exatamente por todos os pontos. Ela foi determinada para representar globalmente o conjunto de dados segundo o critério dos mínimos quadrados.

Primeira interpretação dos coeficientes

O coeficiente angular encontrado foi:

$$a = 1,070828.$$

Como:

$$a > 1,$$

o modelo indica que, ao longo da faixa analisada, a indicação do PT100 cresce, em média segundo o ajuste linear, mais rapidamente que a indicação do DT-670.

Para cada aumento de aproximadamente:

$$1 \text{ K}$$

em T_{DT670} , o modelo associa um aumento de aproximadamente:

$$1,071 \text{ K}$$

em T_{PT100} .

O intercepto encontrado foi:

$$b = -0,125876 \text{ K}.$$

Como discutido anteriormente, esse valor é um parâmetro da reta ajustada. Ele não deve ser interpretado como uma medição física do PT100 em 0 K, pois essa temperatura está fora da faixa dos dados utilizados no ajuste e o conjunto é didático e simulado.

A comparação completa entre:

$$a = 1,070828, \quad b = -0,125876$$

e a condição ideal:

$$a = 1, \quad b = 0$$

será realizada após a análise da qualidade do ajuste. O próximo passo consiste, portanto, em responder a uma nova questão:

Quão bem essa reta representa os 21 pontos do conjunto de dados?

Para isso, será calculado o coeficiente de determinação R^2 .

9. Coeficiente de determinação R^2

No item anterior foi obtido o modelo de regressão linear:

$$\hat{T}_{\text{PT100}} = 1,070828T_{\text{DT670}} - 0,125876.$$

A existência de uma reta ajustada, entretanto, não informa por si só quanto essa reta consegue representar a variação observada nos dados. Para avaliar a qualidade do ajuste linear, pode-se utilizar o **coeficiente de determinação**, representado por:

$$R^2.$$

Antes de calcular esse coeficiente, é importante compreender as grandezas envolvidas em sua definição.

Valor observado, valor estimado e valor médio

Para cada ponto de medição existem três valores importantes. O primeiro é o valor efetivamente presente no conjunto de dados:

$$T_{\text{PT100},i}.$$

O segundo é o valor estimado pelo modelo de regressão:

$$\hat{T}_{\text{PT100},i}.$$

O terceiro é a média das temperaturas indicadas pelo PT100:

$$\bar{T}_{\text{PT100}} = \frac{1}{n} \sum_{i=1}^n T_{\text{PT100},i}.$$

Essas três grandezas permitem comparar a dispersão original dos dados com a parcela dessa dispersão que permanece sem ser representada pelo modelo linear.

Soma dos quadrados dos resíduos

Como visto anteriormente, o resíduo associado ao ponto i é:

$$r_i = T_{\text{PT100},i} - \hat{T}_{\text{PT100},i}.$$

A soma dos quadrados dos resíduos pode ser escrita como:

$$SS_{\text{res}} = \sum_{i=1}^n \left(T_{\text{PT100},i} - \hat{T}_{\text{PT100},i} \right)^2$$

Essa grandeza quantifica a parcela da variação dos valores observados que permanece nos resíduos do modelo. Quanto menores forem as diferenças entre os valores observados e os valores estimados, menor será SS_{res} .

Soma total dos quadrados

Também é possível medir quanto os valores observados do PT100 variam em relação à própria média. Essa grandeza é denominada soma total dos quadrados:

$$SS_{\text{tot}} = \sum_{i=1}^n (T_{\text{PT100},i} - \bar{T}_{\text{PT100}})^2$$

Assim, enquanto SS_{res} mede a dispersão que permanece após o ajuste do modelo, SS_{tot} representa a dispersão total dos valores observados em relação à média.

Definição do coeficiente de determinação

O coeficiente de determinação pode ser calculado por:

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

Se os valores previstos pela reta estiverem muito próximos dos valores observados, então:

$$SS_{\text{res}} \ll SS_{\text{tot}},$$

e, conseqüentemente:

$$R^2 \rightarrow 1.$$

Para uma regressão linear com intercepto como a utilizada neste exercício, um valor de R^2 próximo da unidade indica que o modelo linear representa uma parcela muito elevada da variabilidade observada em T_{PT100} . Entretanto, essa informação deve ser interpretada corretamente. Um valor elevado de R^2 indica uma forte adequação do modelo linear à relação observada entre as variáveis, mas não demonstra, isoladamente, que:

$$T_{\text{PT100}} = T_{\text{DT670}}.$$

Essas são duas questões diferentes.

Cálculo utilizando Python

Como a coluna `PT100_estimado_K` já foi criada anteriormente, podem-se calcular diretamente as somas dos quadrados:

```
# Média das temperaturas indicadas pelo PT100
media_PT100 = tabela["PT100_K"].mean()

# Soma dos quadrados dos resíduos
SS_res = np.sum(
    (
        tabela["PT100_K"]
        - tabela["PT100_estimado_K"]
    ) ** 2
```

```

)

# Soma total dos quadrados
SS_tot = np.sum(
    (
        tabela["PT100_K"]
        - media_PT100
    ) ** 2
)

# Coeficiente de determinação
R2 = 1 - (SS_res / SS_tot)

# Apresentação dos resultados
print("-----")
print("Coeficiente de determinação")
print("-----")
print(f"SS_res = {SS_res:.6f}")
print(f"SS_tot = {SS_tot:.6f}")
print(f"R² = {R2:.6f}")

```

Saída numérica:

```

-----
Coeficiente de determinação
-----

```

```

SS_res = 0.467906
SS_tot = 4937.432314
R2 = 0.999905

```

Para o conjunto de dados analisado, obtém-se aproximadamente:

$$R^2 = 0,999905$$

Esse valor está muito próximo da unidade.

Isso significa que, dentro do conjunto de dados analisado, a relação entre as indicações do DT-670 e do PT100 é muito bem representada por um modelo linear. Entretanto, ainda não se pode concluir que existe concordância entre as indicações dos sensores. Para compreender essa diferença, é necessário comparar a reta ajustada com a reta correspondente à concordância ideal.

10. Comparação entre a regressão e a concordância ideal

Até este ponto foram obtidas duas relações matemáticas distintas. A primeira corresponde ao modelo ajustado aos dados:

$$\widehat{T}_{\text{PT100}} = 1,070828T_{\text{DT670}} - 0,125876$$

A segunda corresponde à condição de concordância ideal:

$$T_{\text{PT100}} = T_{\text{DT670}}$$

ou simplesmente:

$$y = x$$

Na condição de concordância ideal, os parâmetros da reta seriam:

$$a = 1$$

e

$$b = 0.$$

Entretanto, para os dados analisados foram encontrados:

$$a = 1,070828$$

e

$$b = -0,125876 \text{ K}.$$

Portanto, embora a relação entre as duas séries seja fortemente linear, a reta ajustada não coincide com a reta de concordância ideal.

Interpretação geométrica

No gráfico de dispersão, a reta:

$$y = x$$

representa o conjunto de pontos para os quais as duas indicações seriam exatamente iguais.

Por exemplo:

$$(10, 10), \quad (20, 20), \quad (30, 30), \quad (40, 40)$$

pertencem à reta de concordância ideal.

Já a reta de regressão representa a tendência efetivamente observada no conjunto de dados simulados. Ao representar as duas retas no mesmo gráfico, torna-se possível visualizar simultaneamente:

- os dados observados;
- a tendência linear dos dados;
- a condição que corresponderia à concordância perfeita entre as indicações.

Construção do gráfico utilizando Python

Como os valores estimados pela regressão já foram armazenados na coluna `PT100_estimado_K`, pode-se construir o gráfico completo:

```
# Criação da figura
plt.figure(figsize=(8, 6))

# Dados experimentais simulados
plt.scatter(
    tabela["DT670_K"],
    tabela["PT100_K"],
    color="black",
    marker="o",
    label="Dados"
)

# Reta de regressão linear
plt.plot(
    tabela["DT670_K"],
    tabela["PT100_estimado_K"],
    color="black",
    linestyle="-",
    label="Regressão linear"
)

# Reta de concordância ideal
plt.plot(
    tabela["DT670_K"], # valores de x
    tabela["DT670_K"], # valores de y = x
    color="black",
    linestyle="--",
    label="Concordância ideal"
```

)

```
# Identificação dos eixos
plt.xlabel("Temperatura indicada pelo DT-670 (K)")
plt.ylabel("Temperatura indicada pelo PT100 (K)")

# Título
plt.title("Regressão linear e concordância ideal")

# Grade e legenda
plt.grid(True)
plt.legend()

# Ajuste automático do espaçamento
plt.tight_layout()

# Exibição do gráfico
plt.show()
```

A Figura 9 apresenta os dados experimentais simulados juntamente com a reta de regressão linear e a reta de concordância ideal entre as indicações do DT-670 e do PT100.




Figura 9: Comparação entre os dados experimentais simulados, a regressão linear e a concordância ideal entre as indicações do DT-670 e do PT100.

Interpretação do gráfico

O gráfico permite observar que os pontos experimentais simulados permanecem muito próximos da reta de regressão.

Esse comportamento é consistente com o elevado valor encontrado para:

$$R^2 = 0,999905.$$

Entretanto, à medida que a temperatura aumenta, a reta de regressão se afasta progressivamente da reta de concordância ideal. Esse resultado é coerente com a análise realizada anteriormente para o erro absoluto.

No início da faixa, para:

$$T_{\text{DT670}} = 4,20 \text{ K},$$

a diferença observada entre as indicações é:

$$4,59 - 4,20 = 0,39 \text{ K}.$$

No final da faixa, para:

$$T_{\text{DT670}} = 50,00 \text{ K},$$

a diferença é:

$$53,75 - 50,00 = 3,75 \text{ K}.$$

Portanto, o gráfico evidencia simultaneamente duas características:

forte relação linear

e

afastamento da condição de concordância ideal

Essas duas características não são contraditórias.

11. Interpretação dos coeficientes da regressão

A interpretação conjunta do coeficiente angular, do intercepto e do coeficiente de determinação permite compreender melhor o comportamento das duas séries de medições.

O modelo obtido foi:

$$\hat{T}_{\text{PT100}} = 1,070828T_{\text{DT670}} - 0,125876.$$

Análise do coeficiente angular

Para a condição de concordância ideal seria esperado:

$$a_{\text{ideal}} = 1.$$

Entretanto, foi obtido:

$$a = 1,070828.$$

A diferença em relação ao valor ideal é:

$$a - a_{\text{ideal}} = 1,070828 - 1.$$

Portanto:

$$a - a_{\text{ideal}} = 0,070828$$

ou, relativamente ao coeficiente angular ideal:

$$0,070828 \times 100 \approx 7,08\%.$$

Isso significa que a inclinação da relação ajustada é aproximadamente 7,08% maior que a inclinação correspondente à concordância ideal. No contexto deste conjunto de dados, esse resultado indica que a indicação do PT100 cresce mais rapidamente que a indicação do DT-670 ao longo da faixa analisada.

Análise do intercepto

Para a concordância ideal:

$$b_{\text{ideal}} = 0.$$

O modelo ajustado forneceu:

$$b = -0,125876 \text{ K}.$$

Portanto, a reta de regressão apresenta um pequeno deslocamento em relação à origem. Entretanto, é necessário ter cuidado com a interpretação física desse parâmetro.

O conjunto de dados analisado começa em:

$$T_{\text{DT670}} = 4,20 \text{ K},$$

e não contém medições próximas de:

$$0 \text{ K}.$$

Assim, interpretar diretamente:

$$b = -0,125876 \text{ K}$$

como uma indicação física do PT100 em 0 K corresponderia a uma extrapolação do modelo para fora da faixa estudada. Neste exercício, b deve ser interpretado principalmente como um parâmetro matemático necessário para posicionar a reta que melhor se ajusta aos dados.

Análise conjunta de a , b e R^2

Os principais resultados da regressão são:

$$a = 1,070828$$

$$b = -0,125876 \text{ K}$$

e

$$R^2 = 0,999905.$$

O elevado valor de R^2 mostra que existe uma relação linear muito forte entre as indicações dos dois sensores no conjunto de dados analisado.

Entretanto:

$$a \neq 1$$

e

$$b \neq 0.$$

Além disso, os erros absolutos mostram que:

$$T_{\text{PT100}} \neq T_{\text{DT670}}$$

nos pontos analisados.

Portanto, deve-se distinguir claramente dois conceitos:

$$\text{qualidade do ajuste linear} \neq \text{concordância entre as indicações}$$

Um valor de R^2 próximo de 1 indica que os dados seguem muito bem uma relação linear. Ele não estabelece que essa relação seja:

$$y = x.$$

Por exemplo, uma relação hipotética:

$$y = 2x + 10$$

poderia apresentar:

$$R^2 = 1$$

se todos os pontos estivessem exatamente sobre essa reta. Ainda assim, essa relação estaria claramente distante da condição:

$$y = x.$$

Esse exemplo mostra por que o coeficiente de determinação não deve ser utilizado isoladamente como medida de concordância entre instrumentos.

Conclusão parcial

A regressão linear mostrou que as indicações dos sensores apresentam uma relação fortemente linear na faixa estudada.

Entretanto, a comparação com a reta:

$$T_{\text{PT100}} = T_{\text{DT670}}$$

mostrou que existe um afastamento sistemático entre as indicações.

O coeficiente angular superior à unidade é consistente com o crescimento do erro absoluto observado anteriormente. Assim, diferentes ferramentas utilizadas até este ponto fornecem informações complementares:

- o erro absoluto, E_{abs} , informa a magnitude do afastamento entre as indicações, expressa em kelvin;
- o erro relativo, E_{rel} , expressa esse afastamento em relação à magnitude da temperatura utilizada como referência;
- os coeficientes a e b caracterizam a forma da relação linear entre as indicações dos sensores;
- o coeficiente de determinação R^2 fornece uma medida da qualidade do ajuste do modelo linear aos dados.

Entretanto, ainda resta uma questão importante.

Mesmo apresentando:

$$R^2 \approx 1,$$

os pontos não estão exatamente sobre a reta de regressão.

Existem pequenas diferenças entre:

$$T_{\text{PT100},i}$$

e

$$\hat{T}_{\text{PT100},i}.$$

Essas diferenças correspondem aos resíduos do modelo.

A análise dos resíduos permitirá investigar se os desvios em torno da reta apresentam apenas pequenas variações ou se existe alguma estrutura que o modelo linear não conseguiu representar.

12. Análise dos resíduos da regressão linear

O modelo de regressão linear obtido anteriormente foi:

$$\hat{T}_{\text{PT100}} = 1,070828T_{\text{DT670}} - 0,125876.$$

Esse modelo fornece, para cada temperatura indicada pelo DT-670, uma estimativa da temperatura correspondente do PT100. Entretanto, como os pontos experimentais simulados não estão exatamente sobre a reta de regressão, existe uma diferença entre o valor observado e o valor estimado pelo modelo. Essa diferença é denominada **resíduo**.

Para cada ponto de medição:

$$r_i = T_{\text{PT100},i} - \hat{T}_{\text{PT100},i}$$

em que:

- $T_{\text{PT100},i}$ representa o valor observado;
- $\hat{T}_{\text{PT100},i}$ representa o valor estimado pelo modelo de regressão;
- r_i representa o resíduo associado ao ponto de medição.

Interpretação do sinal do resíduo

O sinal do resíduo fornece uma informação importante.

Quando:

$$r_i > 0,$$

o valor observado está acima do valor previsto pela reta de regressão.

Quando:

$$r_i < 0,$$

o valor observado está abaixo do valor previsto pela reta.

Quando:

$$r_i = 0,$$

o ponto está exatamente sobre a reta de regressão.

Portanto:

$$r_i > 0 \implies \text{ponto acima da reta}$$

e:

$$r_i < 0 \implies \text{ponto abaixo da reta}$$

Diferença entre erro e resíduo

Neste exercício é importante distinguir o erro calculado anteriormente do resíduo da regressão. O erro absoluto foi definido por:

$$E_{\text{abs},i} = |T_{\text{PT100},i} - T_{\text{DT670},i}|.$$

Portanto, ele compara diretamente as indicações do PT100 e do DT-670.

Já o resíduo é:

$$r_i = T_{\text{PT100},i} - \hat{T}_{\text{PT100},i}.$$

Assim, o resíduo compara o valor observado do PT100 com o valor previsto pelo modelo de regressão.

Consequentemente:

$$\text{erro absoluto} \neq \text{resíduo da regressão}$$

As duas grandezas respondem a perguntas diferentes.

Cálculo manual para o primeiro ponto

No primeiro ponto:

$$T_{\text{DT670}} = 4,20 \text{ K}$$

e:

$$T_{\text{PT100}} = 4,59 \text{ K}.$$

A temperatura estimada pelo modelo é:

$$\hat{T}_{\text{PT100},1} = 1,070828(4,20) - 0,125876.$$

Portanto:

$$\hat{T}_{\text{PT100},1} \approx 4,372 \text{ K}.$$

O resíduo será:

$$r_1 = 4,59 - 4,372.$$

Logo:

$$r_1 \approx 0,218 \text{ K}$$

Como:

$$r_1 > 0,$$

o primeiro ponto encontra-se acima da reta de regressão.

Cálculo manual para o segundo ponto

Para o segundo ponto:

$$T_{\text{DT670}} = 5,00 \text{ K}$$

e:

$$T_{\text{PT100}} = 5,29 \text{ K}.$$

O modelo fornece:

$$\hat{T}_{\text{PT100},2} = 1,070828(5,00) - 0,125876.$$

Assim:

$$\hat{T}_{\text{PT100},2} \approx 5,228 \text{ K}.$$

Portanto:

$$r_2 = 5,29 - 5,228,$$

resultando em aproximadamente:

$$r_2 \approx 0,062 \text{ K}$$

Novamente:

$$r_2 > 0,$$

indicando que o valor observado está ligeiramente acima daquele previsto pela regressão.

Cálculo utilizando Python

Como a coluna `PT100_estimado_K` já foi criada anteriormente, os resíduos podem ser calculados diretamente:

```
# Cálculo dos resíduos da regressão
tabela["residuo_K"] = (
    tabela["PT100_K"]
    - tabela["PT100_estimado_K"]
)

# Visualização dos resultados
print(
    tabela[
        [
            "ponto",
            "DT670_K",
            "PT100_K",
            "PT100_estimado_K",
            "residuo_K"
        ]
    ]
)
```

A nova coluna `residuo_K` contém, portanto, a diferença entre cada valor observado e o valor correspondente estimado pelo modelo.

Construção do gráfico dos resíduos

Uma maneira particularmente útil de avaliar os resíduos consiste em representá-los em função da variável independente utilizada na regressão.

Neste exercício, será construído o gráfico:

$$r_i \text{ em função de } T_{\text{DT670}}.$$

O código é:

```
# Criação da figura
```

```

plt.figure(figsize=(10, 6))

# Resíduos da regressão
plt.scatter(
    tabela["DT670_K"],
    tabela["residuo_K"],
    color="black",
    marker="o",
    label="Resíduos"
)

# Linha correspondente a resíduo igual a zero
plt.axhline(
    y=0,
    color="black",
    linestyle="--",
    label="Resíduo = 0"
)

# Identificação dos eixos
plt.xlabel("Temperatura indicada pelo DT-670 (K)")
plt.ylabel("Resíduo (K)")

# Título
plt.title("Resíduos do modelo de regressão linear")

# Grade e legenda
plt.grid(True)
plt.legend()

# Ajuste automático do espaçamento
plt.tight_layout()

# Exibição do gráfico
plt.show()

```

Gráfico:

Interpretação do gráfico dos resíduos

A linha horizontal:




Figura 10: Evolução da taxa de variação da temperatura, dT/dt , dos sensores A e B em função do tempo durante o processo de aquecimento.

$$r = 0$$

representa a situação em que o valor observado coincide exatamente com o valor estimado pelo modelo. Pontos localizados acima dessa linha apresentam resíduos positivos, enquanto pontos localizados abaixo apresentam resíduos negativos. No conjunto de dados analisado, os resíduos apresentam valores positivos e negativos distribuídos em torno de zero. Além disso, suas magnitudes são pequenas quando comparadas à faixa total de temperaturas analisada.

Esse comportamento é consistente com o elevado coeficiente de determinação obtido anteriormente:

$$R^2 = 0,999905.$$

A inspeção do gráfico não evidencia um afastamento sistemático de grande magnitude dos pontos em relação à reta ajustada. Assim, dentro do objetivo didático deste exercício, o modelo linear representa adequadamente a relação observada entre as duas séries de temperatura. Entretanto, essa conclusão refere-se à capacidade do modelo de representar a relação entre as variáveis. Ela não significa que as indicações do PT100 e do DT-670 sejam iguais.

Essa distinção é fundamental: os resíduos avaliam o comportamento dos dados em relação à **reta de regressão**, enquanto os erros calculados anteriormente avaliam o afastamento do PT100 em relação ao DT-670 adotado como referência.

13. Discussão geral dos resultados

A análise realizada neste exercício utilizou diferentes ferramentas de computação científica para investigar o comportamento das indicações do PT100 em relação ao DT-670 no conjunto

de dados didáticos e simulados. Cada ferramenta forneceu uma informação diferente sobre o problema.

Análise dos erros

O erro absoluto foi definido como:

$$E_{\text{abs}} = |T_{\text{PT100}} - T_{\text{DT670}}|.$$

Considerando os 21 pontos de medição, foi obtido:

$$\overline{E}_{\text{abs}} = 1,5410 \text{ K}$$

para o erro absoluto médio. Já o erro relativo percentual médio foi:

$$\overline{E}_{\text{rel}} = 6,5232\%$$

Esses valores mostram que existe um afastamento entre as indicações dos dois sensores no conjunto de dados analisado. Entretanto, a análise gráfica mostrou que esse afastamento não permanece constante ao longo da faixa de temperatura.

Comportamento do erro ao longo da faixa

No primeiro ponto:

$$T_{\text{DT670}} = 4,20 \text{ K}$$

e:

$$T_{\text{PT100}} = 4,59 \text{ K},$$

resultando em:

$$E_{\text{abs}} = 0,39 \text{ K}.$$

No último ponto:

$$T_{\text{DT670}} = 50,00 \text{ K}$$

e:

$$T_{\text{PT100}} = 53,75 \text{ K},$$

resultando em:

$$E_{\text{abs}} = 3,75 \text{ K}.$$

Portanto, embora ocorram pequenas variações entre pontos consecutivos, o conjunto apresenta uma tendência geral de crescimento do erro absoluto com o aumento da temperatura.

Análise da regressão linear

A relação entre as indicações dos sensores foi representada pelo modelo:

$$\hat{T}_{PT100} = 1,070828T_{DT670} - 0,125876$$

com:

$$R^2 = 0,999905.$$

O valor de R^2 muito próximo da unidade mostra que os dados apresentam uma relação fortemente linear. Entretanto, a condição de concordância ideal seria:

$$T_{PT100} = T_{DT670},$$

correspondente a:

$$a = 1$$

e:

$$b = 0.$$

Os coeficientes obtidos foram:

$$a = 1,070828$$

e:

$$b = -0,125876 \text{ K}.$$

Portanto, a reta ajustada aos dados não coincide com a reta de concordância ideal.

Análise dos resíduos

Os resíduos foram definidos por:

$$r_i = T_{PT100,i} - \hat{T}_{PT100,i}.$$

O gráfico dos resíduos permite analisar os desvios dos pontos em relação à reta ajustada. Para os dados utilizados neste exercício, os resíduos permanecem distribuídos em torno de zero e apresentam pequena magnitude em relação à faixa total de temperatura. Esse resultado reforça a conclusão de que o modelo linear representa adequadamente a relação existente

entre as duas séries de dados. Entretanto, novamente, essa análise avalia a qualidade do modelo de regressão e não a igualdade entre as indicações dos sensores.

Por que R^2 próximo de 1 não demonstra concordância?

Esse é um dos principais resultados conceituais deste exercício. O coeficiente de determinação responde essencialmente à questão:

O modelo linear representa adequadamente a variação observada nos dados?

Já a análise de concordância entre as indicações procura responder a uma questão diferente:

As indicações dos dois sensores apresentam valores suficientemente próximos entre si?

Portanto:

$$\boxed{R^2 \approx 1}$$

não implica necessariamente:

$$\boxed{T_{\text{PT100}} \approx T_{\text{DT670}}}.$$

Um conjunto de pontos pode estar perfeitamente alinhado sobre uma reta e, ao mesmo tempo, essa reta estar afastada da condição de concordância ideal:

$$y = x.$$

Assim, um elevado coeficiente de determinação deve ser analisado em conjunto com outras informações, como:

- os erros entre as indicações;
- o comportamento desses erros ao longo da faixa analisada;
- os coeficientes da regressão;
- a comparação da regressão com a reta de concordância ideal;
- a distribuição dos resíduos.

Conclusão

A aplicação conjunta de Pandas, NumPy e Matplotlib permitiu transformar um conjunto de medições em informações úteis para a análise do comportamento dos sensores. O Pandas foi utilizado para organizar e manipular os dados, o NumPy para realizar operações numéricas e ajustar o modelo de regressão linear, e o Matplotlib para representar graficamente as diferentes etapas da análise. Para o conjunto de dados didáticos e simulados considerado, verificou-se que as indicações do PT100 apresentam uma relação fortemente linear com as indicações do DT-670, mas não coincidem com elas ao longo da faixa analisada. O aumento do erro absoluto com a temperatura e o coeficiente angular da regressão superior à unidade mostram que o afastamento entre as indicações possui uma tendência sistemática dentro do conjunto de dados considerado. Ao mesmo tempo, o elevado valor de R^2 e o comportamento dos resíduos mostram que uma relação linear representa muito bem os dados.

Portanto, o exercício evidencia uma distinção fundamental na análise computacional de dados de instrumentação:

forte relação linear não significa, necessariamente, concordância

Essa distinção é importante porque a avaliação de instrumentos não deve ser baseada em um único indicador estatístico. Erros, tendências, coeficientes do modelo, gráficos e resíduos devem ser analisados de forma conjunta para produzir uma interpretação tecnicamente consistente.

Finalmente, deve-se recordar que os dados utilizados neste exercício são didáticos e simulados. As conclusões obtidas descrevem exclusivamente o conjunto de dados analisado e não devem ser interpretadas como especificações metrológicas reais do DT-670 ou do PT100.

Exercício 4 – Ruído e Filtragem Digital

Em sistemas de instrumentação, os sinais fornecidos por sensores podem apresentar oscilações em torno do valor da variável medida. Essas oscilações podem dificultar a interpretação dos dados e, em determinadas aplicações, tornar necessária a utilização de técnicas de processamento de sinais.

Neste exercício, será analisado um conjunto de dados didáticos contendo as indicações de um sensor de temperatura sujeito a oscilações e as indicações de um sensor adotado como referência. O objetivo é utilizar ferramentas de computação científica para quantificar o afastamento entre as duas indicações e investigar o efeito da aplicação de dois métodos simples de filtragem digital: a média móvel e o filtro exponencial.

Para contextualizar fisicamente o problema, considere um tanque contendo um líquido cuja temperatura é monitorada durante um processo de agitação. O tanque é equipado com um agitador acionado por um motor elétrico e possui dois sensores de temperatura instalados no processo: um sensor de medição, cujo sinal apresenta oscilações, e um sensor adotado

como referência.

Durante a operação, diferentes fatores associados ao processo e à cadeia de medição podem contribuir para as oscilações observadas no sinal adquirido. Entre eles podem estar a movimentação do fluido, vibrações mecânicas associadas ao sistema de agitação, interferências elétricas e outras perturbações presentes no sistema de medição. Neste exercício, entretanto, não será investigada individualmente a origem dessas perturbações. O interesse estará concentrado no sinal resultante e em seu processamento.

As indicações dos dois sensores são enviadas a um sistema de aquisição de dados e posteriormente analisadas computacionalmente. Inicialmente, será calculada a diferença entre o sinal do sensor sujeito às oscilações e o sinal utilizado como referência. Em seguida, serão aplicados métodos de filtragem digital com o objetivo de avaliar como essas oscilações podem ser atenuadas.

A figura 11 representa esquematicamente a situação considerada neste exercício.




Figura 11: Representação esquemática da aquisição e do processamento de sinais de temperatura em um tanque agitado, mostrando o sensor de medição sujeito a oscilações, o sensor de referência e a aplicação da filtragem digital.

A representação da figura deve ser utilizada como referência física ao longo da resolução. Os valores disponíveis no arquivo `sensor_ruidoso.csv` representam as medições adquiridas nesse processo, enquanto os cálculos realizados em Python correspondem às etapas de análise e processamento desses sinais.

Os dados utilizados neste exercício são **didáticos e simulados**, construídos especificamente para o desenvolvimento das técnicas de análise computacional apresentadas a seguir.

Dados experimentais simulados

Os dados estão armazenados no arquivo `sensor_ruidoso.csv`, que contém as seguintes colunas:

- `tempo_s`: tempo de medição, em segundos;
- `sensor_ruidoso_C`: temperatura indicada pelo sensor sujeito às oscilações, em graus Celsius;
- `sensor_referencia_C`: temperatura indicada pelo sensor adotado como referência, em graus Celsius.

O conjunto de dados utilizado no exercício é apresentado a seguir:

```
tempo_s,sensor_ruidoso_C,sensor_referencia_C
0,25.5,25.0
1,26.2,25.1
2,24.8,25.0
3,27.0,25.0
4,23.9,25.0
5,26.8,25.0
6,24.5,25.0
7,27.2,25.0
8,23.8,25.0
9,26.5,25.0
```

Tarefas

1. Carregue o arquivo `sensor_ruidoso.csv` utilizando a biblioteca Pandas e visualize os dados disponíveis.
2. Considerando o sensor de referência como base de comparação, calcule, para cada instante de medição, o ruído do sensor por:

$$r_k = T_{\text{ruidoso},k} - T_{\text{referencia},k}.$$

Adicione os valores calculados ao DataFrame em uma nova coluna denominada `ruído_C`.

3. Para caracterizar quantitativamente o sinal original:
 - (a) determine a média dos valores de ruído;
 - (b) determine o desvio padrão dos valores de ruído;

(c) calcule, para cada instante, o erro absoluto em relação ao sensor de referência:

$$E_{\text{abs},k} = |T_{\text{ruidoso},k} - T_{\text{referencia},k}|;$$

(d) determine o erro absoluto médio do sinal original.

4. Aplique ao sinal do sensor ruidoso um filtro de **média móvel** utilizando uma janela de:

$$N = 3$$

amostras.

Para os pontos iniciais, nos quais ainda não existem três amostras disponíveis, utilize as amostras existentes até aquele instante.

Armazene os valores calculados em uma nova coluna denominada `media_movel_C`.

5. Aplique ao sinal do sensor ruidoso um **filtro exponencial** definido por:

$$T_{F,k} = \alpha T_k + (1 - \alpha) T_{F,k-1},$$

utilizando:

$$\alpha = 0,30.$$

Adote como condição inicial:

$$T_{F,0} = T_0.$$

Armazene os valores calculados em uma nova coluna denominada `filtro_exponencial_C`.

6. Construa os seguintes gráficos:

- (a) sensor ruidoso, sensor de referência e sinal obtido pela média móvel em função do tempo;
- (b) sensor ruidoso, sensor de referência e sinal obtido pelo filtro exponencial em função do tempo;
- (c) sensor ruidoso, média móvel e filtro exponencial em função do tempo.

Utilize os gráficos para observar o efeito de cada método sobre as oscilações presentes no sinal original.

7. Avalie quantitativamente o efeito da filtragem. Para isso, calcule, em cada instante, o erro absoluto do sinal obtido pela média móvel em relação à referência:

$$E_{MM,k} = |T_{MM,k} - T_{\text{referencia},k}|,$$

e o erro absoluto do sinal obtido pelo filtro exponencial:

$$E_{\text{exp},k} = |T_{F,k} - T_{\text{referencia},k}|.$$

Em seguida, determine e compare:

- o erro absoluto médio do sinal original;
 - o erro absoluto médio após a aplicação da média móvel;
 - o erro absoluto médio após a aplicação do filtro exponencial.
8. Com base nos valores calculados e nos gráficos obtidos, analise os resultados e responda:
- (a) Os filtros reduziram as oscilações presentes no sinal original?
 - (b) Houve redução do erro absoluto médio em relação ao sensor de referência?
 - (c) Os dois filtros produziram o mesmo comportamento?
 - (d) Qual é a influência do tamanho da janela N sobre o filtro de média móvel?
 - (e) Qual é a influência do parâmetro α sobre o filtro exponencial?
 - (f) Uma maior suavização do sinal significa necessariamente uma melhor representação da variável medida? Justifique sua resposta com base nos resultados obtidos.

Gabarito do Exercício 4 – Ruído e Filtragem Digital

A análise de sinais provenientes de instrumentos de medição frequentemente envolve situações nas quais a variável registrada apresenta oscilações em torno do valor esperado. Essas oscilações podem estar associadas a diferentes fontes de ruído presentes no sistema de medição, como interferências elétricas, perturbações do processo, limitações do sensor ou efeitos introduzidos pelo sistema de aquisição de dados.

Neste exercício, será analisado um conjunto de dados didáticos contendo as indicações de um sensor de temperatura sujeito a oscilações e as indicações de um sensor adotado como referência. A partir desses dados, inicialmente será quantificado o afastamento entre as duas séries de medições. Posteriormente, serão aplicadas técnicas simples de filtragem digital com o objetivo de investigar como o processamento computacional pode contribuir para a suavização do sinal medido.

A resolução será desenvolvida progressivamente, relacionando a formulação matemática de cada operação com sua implementação utilizando Python. Dessa forma, antes da aplicação dos filtros digitais, é importante compreender e quantificar o ruído presente no sinal original.

1. Leitura e visualização dos dados

O primeiro passo consiste em carregar o arquivo `sensor_ruidoso.csv`, que contém os dados utilizados no exercício, e visualizar sua estrutura no ambiente computacional.

As três colunas disponíveis são:

- `tempo_s`: instante em que a medição foi realizada, em segundos;
- `sensor_ruidoso_C`: temperatura indicada pelo sensor sujeito às oscilações, em graus Celsius;
- `sensor_referencia_C`: temperatura indicada pelo sensor adotado como referência, em graus Celsius.

O arquivo contém os seguintes dados:

```
tempo_s,sensor_ruidoso_C,sensor_referencia_C
0,25.5,25.0
1,26.2,25.1
2,24.8,25.0
3,27.0,25.0
4,23.9,25.0
5,26.8,25.0
6,24.5,25.0
7,27.2,25.0
8,23.8,25.0
9,26.5,25.0
```

Para realizar a análise computacional, inicialmente são importadas as bibliotecas que serão utilizadas ao longo da resolução.

A biblioteca Pandas será utilizada para leitura, organização e manipulação dos dados. A biblioteca NumPy será empregada nas operações numéricas, enquanto a biblioteca Matplotlib será utilizada posteriormente na construção dos gráficos.

No Spyder, o marcador `%%` permite organizar o programa em células. Dessa forma, cada etapa da resolução poderá ser executada separadamente, acompanhando a mesma sequência utilizada no enunciado do exercício.

A primeira célula do programa pode ser escrita como:

```
%%
# -----
```

```
# 1. Leitura e visualização dos dados
# -----

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

# Leitura dos dados experimentais simulados
tabela = pd.read_csv("sensor_ruidoso.csv")

# Visualização dos dados no console
print(tabela)
```

A função `pd.read_csv()` realiza a leitura do arquivo e armazena seu conteúdo em um DataFrame denominado `tabela`. Esse DataFrame será utilizado nas etapas seguintes para armazenar tanto os dados originais quanto os resultados calculados durante a resolução.

Após a execução da célula, o console deverá apresentar uma estrutura equivalente a:

tempo_s	sensor_ruidoso_C	sensor_referencia_C
0	0	25.5
1	1	26.2
2	2	24.8
3	3	27.0
4	4	23.9
5	5	26.8
6	6	24.5
7	7	27.2
8	8	23.8
9	9	26.5

Uma primeira observação dos dados permite perceber que a indicação do sensor de referência permanece próxima de 25 °C, enquanto a indicação do sensor ruidoso apresenta oscilações mais acentuadas ao longo das medições. Entretanto, a inspeção visual da tabela não é suficiente para caracterizar quantitativamente essas diferenças. Para isso, o próximo passo consiste em calcular, em cada instante, o afastamento entre a indicação do sensor ruidoso e a indicação adotada como referência.

2. Cálculo do ruído

Neste exercício, o ruído será representado pela diferença entre a indicação do sensor ruidoso e a indicação do sensor adotado como referência.

Para cada instante de medição k , define-se:

$$r_k = T_{\text{ruidoso},k} - T_{\text{referencia},k}$$

em que $T_{\text{ruidoso},k}$ representa a temperatura indicada pelo sensor ruidoso no instante k , enquanto $T_{\text{referencia},k}$ representa a temperatura indicada pelo sensor de referência no mesmo instante.

É importante observar que, neste momento, estamos calculando uma **diferença com sinal**. Portanto, o resultado pode ser positivo, negativo ou nulo.

Quando

$$r_k > 0,$$

a indicação do sensor ruidoso encontra-se acima da indicação de referência.

Quando

$$r_k < 0,$$

a indicação do sensor ruidoso encontra-se abaixo da indicação de referência.

Quando

$$r_k = 0,$$

as duas indicações coincidem naquele ponto de medição.

Cálculo manual para o primeiro ponto

No primeiro instante:

$$t_0 = 0 \text{ s},$$

temos:

$$T_{\text{ruidoso},0} = 25,5^\circ\text{C}$$

e

$$T_{\text{referencia},0} = 25,0^\circ\text{C}.$$

Aplicando a definição:

$$r_0 = T_{\text{ruidoso},0} - T_{\text{referencia},0},$$

temos:

$$r_0 = 25,5 - 25,0.$$

Portanto:

$$r_0 = 0,5\text{ }^{\circ}\text{C}$$

O sinal positivo indica que, nesse instante, a temperatura indicada pelo sensor ruidoso encontra-se $0,5\text{ }^{\circ}\text{C}$ acima da indicação fornecida pelo sensor de referência.

Cálculo manual para o segundo ponto

No instante:

$$t_1 = 1\text{ s},$$

as indicações são:

$$T_{\text{ruidoso},1} = 26,2\text{ }^{\circ}\text{C}$$

e

$$T_{\text{referencia},1} = 25,1\text{ }^{\circ}\text{C}.$$

Logo:

$$r_1 = 26,2 - 25,1,$$

resultando em:

$$r_1 = 1,1\text{ }^{\circ}\text{C}$$

Novamente, o valor positivo indica que a temperatura fornecida pelo sensor ruidoso está acima da indicação de referência.

Um exemplo de ruído negativo

É importante analisar também um ponto no qual a diferença apresenta sinal negativo. Para:

$$t_2 = 2\text{ s},$$

temos:

$$T_{\text{ruidoso},2} = 24,8\text{ }^{\circ}\text{C}$$

e

$$T_{\text{referencia},2} = 25,0\text{ }^{\circ}\text{C}.$$

Portanto:

$$r_2 = 24,8 - 25,0,$$

e:

$$r_2 = -0,2^\circ\text{C}$$

Nesse caso, o sinal negativo indica que a temperatura fornecida pelo sensor ruidoso encontra-se $0,2^\circ\text{C}$ abaixo da indicação de referência.

Os três primeiros pontos permitem perceber uma característica importante do sinal analisado: as diferenças podem ocorrer tanto acima quanto abaixo da referência. Portanto, apenas observar o sinal de r_k não é suficiente para avaliar a magnitude global dos afastamentos presentes nas medições.

Essa distinção será importante posteriormente, quando forem analisadas a média, a dispersão e a magnitude dos erros associados ao sinal.

Cálculo utilizando Python

Como as duas séries de temperaturas estão armazenadas em colunas do mesmo Data-Frame, o cálculo pode ser realizado diretamente entre essas colunas:

```
#%%
# -----
# 2. Cálculo do ruído
# -----

tabela["ruído_C"] = (
    tabela["sensor_ruidoso_C"]
    - tabela["sensor_referencia_C"]
)

# Visualização dos resultados
print(
    tabela[
        [
            "tempo_s",
            "sensor_ruidoso_C",
            "sensor_referencia_C",
            "ruído_C"
        ]
    ]
)
```

A operação é realizada elemento a elemento. Assim, para cada linha do DataFrame, o Python subtrai a indicação do sensor de referência da indicação do sensor ruidoso.

A nova coluna **ruido_C** passa, portanto, a representar a diferença entre as duas indicações em cada instante de medição.

É importante distinguir essa grandeza do **erro absoluto**, que será calculado posteriormente. O ruído definido nesta etapa preserva o sinal da diferença:

$$r_k = T_{\text{ruidoso},k} - T_{\text{referencia},k},$$

enquanto o erro absoluto considera apenas a magnitude do afastamento:

$$E_{\text{abs},k} = |T_{\text{ruidoso},k} - T_{\text{referencia},k}|.$$

Dessa forma, valores positivos e negativos de r_k permitem identificar se a indicação do sensor ruidoso está, respectivamente, acima ou abaixo da referência, enquanto $E_{\text{abs},k}$ informa apenas a magnitude desse afastamento.

Essa distinção será importante na próxima etapa, quando o sinal original será caracterizado quantitativamente por meio da média e do desvio padrão do ruído, bem como do erro absoluto e do erro absoluto médio.

3. Caracterização quantitativa do sinal original

Após calcular a diferença entre a indicação do sensor ruidoso e a indicação do sensor de referência em cada ponto de medição, podemos avançar para uma caracterização quantitativa do sinal original.

Até este momento, cada valor da coluna **ruido_C** representa:

$$r_k = T_{\text{ruidoso},k} - T_{\text{referencia},k}.$$

Entretanto, observar individualmente os valores de r_k não fornece uma medida global do comportamento das diferenças entre as indicações. Para caracterizar quantitativamente o sinal original, serão determinadas quatro grandezas:

- média do ruído;
- desvio padrão do ruído;
- erro absoluto em cada instante de medição;
- erro absoluto médio em relação à referência.

Essas grandezas fornecem informações diferentes e complementares sobre o comportamento das medições.

3.1 Média do ruído

Considerando um conjunto contendo n valores de ruído, a média pode ser calculada por:

$$\bar{r} = \frac{1}{n} \sum_{k=0}^{n-1} r_k$$

Para os dados deste exercício, os valores do ruído são obtidos pela diferença entre as duas indicações:

$$r_k = T_{\text{ruidoso},k} - T_{\text{referencia},k}.$$

Como o conjunto possui dez pontos de medição, numerados de 0 a 9, temos:

$$r_0 = 25,5 - 25,0 = 0,5,$$

$$r_1 = 26,2 - 25,1 = 1,1,$$

$$r_2 = 24,8 - 25,0 = -0,2,$$

$$r_3 = 27,0 - 25,0 = 2,0,$$

$$r_4 = 23,9 - 25,0 = -1,1,$$

$$r_5 = 26,8 - 25,0 = 1,8,$$

$$r_6 = 24,5 - 25,0 = -0,5,$$

$$r_7 = 27,2 - 25,0 = 2,2,$$

$$r_8 = 23,8 - 25,0 = -1,2,$$

$$r_9 = 26,5 - 25,0 = 1,5.$$

Portanto:

$$\bar{r} = \frac{0,5 + 1,1 - 0,2 + 2,0 - 1,1 + 1,8 - 0,5 + 2,2 - 1,2 + 1,5}{10}.$$

A soma dos valores é:

$$\sum_{k=0}^9 r_k = 6,1 \text{ }^{\circ}\text{C}.$$

Logo:

$$\boxed{\bar{r} = 0,61 \text{ }^{\circ}\text{C}}$$

O valor positivo da média indica que, considerando o conjunto analisado, as indicações do sensor ruidoso apresentam uma tendência média de permanecer acima das indicações do sensor de referência.

Entretanto, a média do ruído deve ser interpretada com cuidado. Como existem valores positivos e negativos, parte das diferenças pode se cancelar durante o cálculo da média.

Por exemplo, dois valores de ruído iguais a:

$$+1\text{ }^{\circ}\text{C}$$

e

$$-1\text{ }^{\circ}\text{C}$$

produzem média igual a:

$$\frac{1 + (-1)}{2} = 0.$$

Isso não significa que não houve afastamento em relação à referência. Houve uma diferença de $1\text{ }^{\circ}\text{C}$ em cada medição, porém em sentidos opostos.

Essa observação mostra por que a média do ruído, isoladamente, não é suficiente para caracterizar o comportamento das medições.

3.2 Desvio padrão do ruído

Para avaliar a dispersão dos valores de ruído em torno de sua média, podemos utilizar o desvio padrão.

Neste exercício, os dados serão tratados como uma amostra de medições. Portanto, será utilizado o desvio padrão amostral:

$$s_r = \sqrt{\frac{\sum_{k=0}^{n-1} (r_k - \bar{r})^2}{n-1}}$$

O termo

$$r_k - \bar{r}$$

representa o afastamento de cada valor de ruído em relação à média dos valores observados.

Ao elevar esses afastamentos ao quadrado, evita-se o cancelamento entre valores positivos e negativos.

Para os dados deste exercício:

$$\bar{r} = 0,61\text{ }^{\circ}\text{C}.$$

Para o primeiro valor:

$$r_0 - \bar{r} = 0,50 - 0,61 = -0,11\text{ }^{\circ}\text{C}.$$

Para o segundo:

$$r_1 - \bar{r} = 1,10 - 0,61 = 0,49^\circ\text{C}.$$

O mesmo procedimento é realizado para todos os pontos de medição.

Os quadrados dos afastamentos são:

$$\begin{aligned}(r_0 - \bar{r})^2 &= (-0,11)^2 = 0,0121, \\(r_1 - \bar{r})^2 &= (0,49)^2 = 0,2401, \\(r_2 - \bar{r})^2 &= (-0,81)^2 = 0,6561, \\(r_3 - \bar{r})^2 &= (1,39)^2 = 1,9321, \\(r_4 - \bar{r})^2 &= (-1,71)^2 = 2,9241, \\(r_5 - \bar{r})^2 &= (1,19)^2 = 1,4161, \\(r_6 - \bar{r})^2 &= (-1,11)^2 = 1,2321, \\(r_7 - \bar{r})^2 &= (1,59)^2 = 2,5281, \\(r_8 - \bar{r})^2 &= (-1,81)^2 = 3,2761, \\(r_9 - \bar{r})^2 &= (0,89)^2 = 0,7921.\end{aligned}$$

Somando esses valores:

$$\sum_{k=0}^9 (r_k - \bar{r})^2 = 15,009.$$

Como:

$$n = 10,$$

temos:

$$n - 1 = 9.$$

Portanto:

$$s_r = \sqrt{\frac{15,009}{9}}.$$

Logo:

$$s_r = \sqrt{1,667666\dots},$$

resultando em:

$$\boxed{s_r \approx 1,2914^\circ\text{C}}$$

Esse valor fornece uma medida da dispersão das diferenças entre o sensor ruidoso e o sensor de referência em torno da média do ruído.

Quanto maior o desvio padrão, maior é a dispersão dos valores de r_k em torno de seu valor médio.

3.3 Erro absoluto

A média e o desvio padrão fornecem informações importantes sobre os valores de ruído. Entretanto, para avaliar diretamente a magnitude do afastamento entre as duas indicações em cada instante, podemos utilizar o erro absoluto.

Para cada ponto de medição, define-se:

$$E_{\text{abs},k} = |T_{\text{ruidoso},k} - T_{\text{referencia},k}|$$

Como anteriormente definimos:

$$r_k = T_{\text{ruidoso},k} - T_{\text{referencia},k},$$

podemos escrever:

$$E_{\text{abs},k} = |r_k|$$

Para os três primeiros pontos, por exemplo:

$$E_{\text{abs},0} = |0,5| = 0,5^\circ\text{C},$$

$$E_{\text{abs},1} = |1,1| = 1,1^\circ\text{C},$$

e:

$$E_{\text{abs},2} = |-0,2| = 0,2^\circ\text{C}.$$

Observe que o terceiro valor do ruído é negativo:

$$r_2 = -0,2^\circ\text{C},$$

mas seu erro absoluto é:

$$E_{\text{abs},2} = 0,2^\circ\text{C}.$$

Portanto, diferentemente de r_k , o erro absoluto não informa se a indicação do sensor ruidoso está acima ou abaixo da referência. Ele informa apenas a magnitude do afastamento entre as duas indicações.

Para o conjunto completo, os erros absolutos são:

$$\begin{aligned}
E_{\text{abs},0} &= 0,5 \text{ }^{\circ}\text{C}, \\
E_{\text{abs},1} &= 1,1 \text{ }^{\circ}\text{C}, \\
E_{\text{abs},2} &= 0,2 \text{ }^{\circ}\text{C}, \\
E_{\text{abs},3} &= 2,0 \text{ }^{\circ}\text{C}, \\
E_{\text{abs},4} &= 1,1 \text{ }^{\circ}\text{C}, \\
E_{\text{abs},5} &= 1,8 \text{ }^{\circ}\text{C}, \\
E_{\text{abs},6} &= 0,5 \text{ }^{\circ}\text{C}, \\
E_{\text{abs},7} &= 2,2 \text{ }^{\circ}\text{C}, \\
E_{\text{abs},8} &= 1,2 \text{ }^{\circ}\text{C}, \\
E_{\text{abs},9} &= 1,5 \text{ }^{\circ}\text{C}.
\end{aligned}$$

3.4 Erro absoluto médio

Depois de calcular o erro absoluto em cada instante, podemos determinar uma medida global da magnitude dos afastamentos por meio do erro absoluto médio:

$$\overline{E}_{\text{abs}} = \frac{1}{n} \sum_{k=0}^{n-1} E_{\text{abs},k}$$

Para os dados do exercício:

$$\overline{E}_{\text{abs}} = \frac{0,5 + 1,1 + 0,2 + 2,0 + 1,1 + 1,8 + 0,5 + 2,2 + 1,2 + 1,5}{10}.$$

A soma dos erros absolutos é:

$$\sum_{k=0}^9 E_{\text{abs},k} = 12,1 \text{ }^{\circ}\text{C}.$$

Portanto:

$$\overline{E}_{\text{abs}} = \frac{12,1}{10},$$

resultando em:

$$\overline{E}_{\text{abs}} = 1,21 \text{ }^{\circ}\text{C}$$

Diferentemente da média do ruído, o erro absoluto médio não permite que afastamentos positivos e negativos se cancelem. Por esse motivo, ele fornece uma medida da magnitude média das diferenças entre o sensor ruidoso e o sensor adotado como referência.

Neste ponto, portanto, o sinal original pode ser caracterizado pelos seguintes resultados:

$$\overline{r} = 0,61 \text{ }^{\circ}\text{C}$$

$$s_r \approx 1,2914^\circ\text{C}$$

e:

$$\overline{E}_{\text{abs}} = 1,21^\circ\text{C}$$

Esses valores estabelecem uma referência quantitativa para o sinal antes da aplicação dos filtros digitais. Posteriormente, o erro absoluto médio será calculado novamente para os sinais filtrados, permitindo verificar quantitativamente o efeito da filtragem.

3.5 Cálculo utilizando Python

As grandezas determinadas anteriormente podem ser calculadas diretamente a partir do DataFrame.

Como a coluna `ruido_C` já foi criada, a média e o desvio padrão do ruído podem ser obtidos utilizando, respectivamente, os métodos `mean()` e `std()` do Pandas.

O método `std()` utiliza, por padrão, o desvio padrão amostral. Dessa forma, o cálculo realizado pelo Pandas corresponde à expressão utilizada anteriormente:

$$s_r = \sqrt{\frac{\sum_{k=0}^{n-1} (r_k - \bar{r})^2}{n-1}}.$$

Como também foi estabelecido que:

$$E_{\text{abs},k} = |r_k|,$$

a coluna contendo o erro absoluto pode ser construída diretamente a partir da coluna `ruido_C`, utilizando a função `abs()` do NumPy.

A terceira célula do programa pode ser escrita como:

```
#%%
# -----
# 3. Caracterização quantitativa do sinal original
# -----

# Média do ruído
ruido_medio = tabela["ruido_C"].mean()

# Desvio padrão amostral do ruído
desvio_ruido = tabela["ruido_C"].std()

# Erro absoluto em cada ponto de medição
```

```

tabela["erro_original_C"] = np.abs(
tabela["ruído_C"]
)

# Erro absoluto médio
erro_original_medio = tabela["erro_original_C"].mean()

# Apresentação dos resultados
print("-----")
print("Caracterização do sinal original")
print("-----")
print(f"Ruído médio = {ruído_medio:.4f} °C")
print(f"Desvio padrão do ruído = {desvio_ruído:.4f} °C")
print(f"Erro absoluto médio = {erro_original_medio:.4f} °C")
print("-----")

```

A saída esperada é:

```

-----
Caracterização do sinal original
-----
Ruído médio = 0.6100 °C
Desvio padrão do ruído = 1.2914 °C
Erro absoluto médio = 1.2100 °C
-----

```

Os resultados obtidos computacionalmente coincidem com aqueles determinados anteriormente.

A média do ruído,

$$\bar{r} = 0,61\text{ °C},$$

indica que, considerando o conjunto analisado, existe uma tendência média positiva da indicação do sensor ruidoso em relação à indicação de referência.

O desvio padrão amostral,

$$s_r \approx 1,2914\text{ °C},$$

quantifica a dispersão dos valores de ruído em torno de sua média.

Finalmente, o erro absoluto médio,

$$\overline{E}_{\text{abs}} = 1,21\text{ °C},$$

quantifica a magnitude média do afastamento entre as duas indicações, sem considerar se o sensor ruidoso apresenta valores acima ou abaixo da referência.

Esses resultados estabelecem a condição quantitativa do sinal original antes da aplicação dos filtros digitais. Posteriormente, o afastamento em relação à referência será novamente calculado para os sinais filtrados, permitindo comparar quantitativamente o comportamento do sinal antes e depois da filtragem.

4. Aplicação do filtro de média móvel

Os resultados anteriores mostram que o sinal fornecido pelo sensor ruidoso apresenta oscilações em relação à indicação utilizada como referência. Uma possibilidade para reduzir essas oscilações consiste em aplicar um **filtro digital** aos dados medidos.

De maneira geral, um filtro digital recebe uma sequência de valores de entrada,

$$x_0, x_1, x_2, \dots, x_k,$$

e produz uma nova sequência,

$$y_0, y_1, y_2, \dots, y_k,$$

na qual determinadas características do sinal original podem ser atenuadas ou realçadas.

Neste exercício, o interesse está na **suavização das oscilações**. Assim, podemos representar conceitualmente o processamento como:

Sinal medido $\longrightarrow$ Filtro digital $\longrightarrow$ Sinal filtrado
--

Entretanto, a filtragem não deve ser interpretada simplesmente como uma operação capaz de “corrigir” qualquer medição.

Ao suavizar oscilações rápidas, um filtro também pode modificar a resposta temporal do sinal. Dependendo dos parâmetros utilizados, essa suavização pode produzir atraso ou reduzir a capacidade do sinal filtrado de acompanhar variações rápidas da grandeza medida.

Portanto, existe um compromisso importante entre:

redução das oscilações	e	capacidade de acompanhar mudanças do processo
------------------------	---	---

Essa questão é particularmente importante em Instrumentação e Controle de Processos, pois o sinal filtrado pode posteriormente ser utilizado por um sistema de supervisão, por um algoritmo de controle ou por uma lógica de decisão.

Neste exercício serão analisadas duas estratégias simples de filtragem: a média móvel, estudada nesta etapa, e o filtro exponencial, analisado posteriormente.

Antes de implementar o filtro de média móvel em Python, é necessário compreender seu princípio de funcionamento e, principalmente, o significado do tamanho da janela de

filtragem, representado por N .

4.1 Princípio de funcionamento da média móvel

Uma das formas mais simples de reduzir oscilações presentes em um sinal medido consiste em substituir cada valor por uma média calculada a partir de um determinado número de amostras.

Esse procedimento é denominado **média móvel**.

Considere uma sequência de temperaturas medidas:

$$T_0, T_1, T_2, \dots, T_k.$$

Para calcular a média móvel, é necessário definir quantas amostras serão utilizadas em cada cálculo. Esse número é denominado **tamanho da janela** e será representado por:

$$N.$$

Quando já existem pelo menos N amostras disponíveis, a média móvel utilizando as N amostras mais recentes pode ser escrita como:

$$T_{\text{MM},k} = \frac{1}{N} \sum_{i=0}^{N-1} T_{k-i}$$

em que:

- $T_{\text{MM},k}$ representa o valor filtrado no instante k ;
- T_{k-i} representa uma das amostras utilizadas no cálculo;
- N representa o número de amostras consideradas na janela.

Neste exercício será adotada uma janela contendo três amostras:

$$N = 3$$

Assim, a partir do momento em que três medições estiverem disponíveis, o valor filtrado será calculado por:

$$T_{\text{MM},k} = \frac{T_k + T_{k-1} + T_{k-2}}{3}$$

Portanto, cada novo valor filtrado depende da medição atual e das duas medições imediatamente anteriores.

4.2 Significado do tamanho da janela N

O valor de N possui influência direta sobre o comportamento do filtro.

Uma janela pequena utiliza poucas amostras no cálculo da média e, por isso, tende a acompanhar mais rapidamente as mudanças presentes no sinal.

Uma janela maior utiliza um número maior de amostras e tende a produzir uma curva mais suave. Entretanto, ao considerar um histórico maior de medições, o sinal filtrado pode responder mais lentamente às mudanças da variável medida.

De maneira qualitativa:

N pequeno $\longrightarrow$ menor suavização e resposta mais rápida

enquanto:

N grande $\longrightarrow$ maior suavização e resposta potencialmente mais lenta.

Portanto, a escolha de N representa um compromisso entre a redução das oscilações e a capacidade do sinal filtrado de acompanhar alterações da variável de processo.

Neste exercício, a escolha

$$N = 3$$

é utilizada com finalidade didática. Como o conjunto possui apenas dez pontos de medição, uma janela contendo três amostras permite visualizar o efeito da filtragem sem produzir uma suavização excessiva.

4.3 Cálculo manual da média móvel

Vamos analisar inicialmente os valores fornecidos pelo sensor ruidoso:

$$25,5, \quad 26,2, \quad 24,8, \quad 27,0, \quad 23,9, \quad \dots$$

Como foi adotado:

$$N = 3,$$

a partir do terceiro ponto já existem três amostras disponíveis para o cálculo completo da média móvel.

Primeiro ponto: $t = 0\text{ s}$

No primeiro instante existe apenas uma medição disponível:

$$T_0 = 25,5^\circ\text{C}.$$

Ainda não existem três amostras para formar uma janela completa.

Neste exercício, será adotado o critério de utilizar todas as amostras disponíveis enquanto a janela ainda não estiver completa.

Portanto:

$$T_{\text{MM},0} = T_0,$$

e:

$$\boxed{T_{\text{MM},0} = 25,5^\circ\text{C}}$$

Segundo ponto: $t = 1\text{ s}$

Agora existem duas medições disponíveis:

$$T_0 = 25,5^\circ\text{C}$$

e

$$T_1 = 26,2^\circ\text{C}.$$

Como ainda não existem três amostras, calculamos a média utilizando os dois valores disponíveis:

$$T_{\text{MM},1} = \frac{T_0 + T_1}{2}.$$

Substituindo os valores:

$$T_{\text{MM},1} = \frac{25,5 + 26,2}{2},$$

portanto:

$$\boxed{T_{\text{MM},1} = 25,85^\circ\text{C}}$$

Terceiro ponto: $t = 2\text{ s}$

A partir deste instante já existem três medições disponíveis:

$$T_0 = 25,5^\circ\text{C},$$

$$T_1 = 26,2^\circ\text{C}$$

e

$$T_2 = 24,8^\circ\text{C}.$$

A janela está agora completa. Portanto:

$$T_{\text{MM},2} = \frac{T_0 + T_1 + T_2}{3}.$$

Substituindo:

$$T_{\text{MM},2} = \frac{25,5 + 26,2 + 24,8}{3}.$$

Logo:

$$T_{\text{MM},2} = \frac{76,5}{3},$$

resultando em:

$$\boxed{T_{\text{MM},2} = 25,50^\circ\text{C}}$$

Quarto ponto: $t = 3\text{ s}$

Quando uma nova medição é adquirida:

$$T_3 = 27,0^\circ\text{C},$$

a janela se desloca.

O valor mais antigo, T_0 , deixa de participar do cálculo, e passam a ser considerados:

$$T_1, \quad T_2, \quad T_3.$$

Assim:

$$T_{\text{MM},3} = \frac{T_1 + T_2 + T_3}{3}.$$

Substituindo os valores:

$$T_{\text{MM},3} = \frac{26,2 + 24,8 + 27,0}{3}.$$

Portanto:

$$T_{\text{MM},3} = \frac{78,0}{3},$$

e:

$$\boxed{T_{\text{MM},3} = 26,00^\circ\text{C}}$$

Esse deslocamento sucessivo da janela é justamente o que dá origem ao nome **média móvel**.

4.4 Visualização do deslocamento da janela

Para $N = 3$, a partir do momento em que três amostras estão disponíveis, o deslocamento da janela pode ser representado da seguinte maneira:

$$T_{\text{MM},2} = \frac{T_0 + T_1 + T_2}{3},$$

$$T_{\text{MM},3} = \frac{T_1 + T_2 + T_3}{3},$$

$$T_{\text{MM},4} = \frac{T_2 + T_3 + T_4}{3},$$

$$T_{\text{MM},5} = \frac{T_3 + T_4 + T_5}{3}.$$

Observe que, a cada nova medição, a janela avança uma posição. A amostra mais antiga deixa de participar do cálculo e a amostra mais recente passa a integrar a janela.

Por exemplo, no cálculo de $T_{\text{MM},2}$ são utilizadas as amostras

$$T_0, \quad T_1, \quad T_2.$$

No instante seguinte, para calcular $T_{\text{MM},3}$, a amostra T_0 deixa a janela e a nova amostra T_3 passa a fazer parte do cálculo:

$$T_1, \quad T_2, \quad T_3.$$

Esse deslocamento sucessivo da janela é justamente o que caracteriza a **média móvel**. Dessa forma, o valor filtrado é continuamente atualizado à medida que novas medições são adquiridas.

4.5 Implementação da média móvel utilizando Python

No Pandas, a média móvel pode ser calculada utilizando o método `rolling()`.

Para uma janela de três amostras, a quarta célula do programa pode ser escrita como:

```
##  
# -----  
# 4. Aplicação do filtro de média móvel  
# -----  
  
# Número de amostras da janela  
N = 3  
  
# Cálculo da média móvel  
tabela["media_movel_C"] = (
```



```
tabela["sensor_ruidoso_C"]
.rolling(window=N, min_periods=1)
.mean()
)

# Visualização dos resultados
print(
tabela[
[
"tempo_s",
"sensor_ruidoso_C",
"sensor_referencia_C",
"media_movel_C"
]
]
)
```

O argumento

`window=N`

define o número máximo de amostras consideradas em cada janela.
Como neste exercício:

$$N = 3,$$

a média móvel utiliza até três valores consecutivos do sinal, considerando a medição atual e as medições imediatamente anteriores.

4.6 Por que utilizar `min_periods=1`?

Existe uma questão importante no início da série de dados.
No instante:

$$t_0 = 0 \text{ s},$$

existe apenas uma amostra disponível.
No instante:

$$t_1 = 1 \text{ s},$$

existem apenas duas amostras disponíveis.
Somente no instante:

$$t_2 = 2\text{ s}$$

passamos a possuir as três amostras necessárias para completar uma janela de tamanho:

$$N = 3.$$

Se exigíssemos que todas as janelas possuíssem necessariamente três amostras, os dois primeiros valores da média móvel não poderiam ser calculados. Nesse caso, eles apareceriam no DataFrame como valores ausentes, representados pelo Pandas por NaN.

Neste exercício utilizamos:

`min_periods=1`

para informar ao Pandas que a média pode ser calculada a partir de uma única amostra disponível, mesmo que a janela completa de três valores ainda não tenha sido formada.

Consequentemente, no primeiro ponto:

$$T_{\text{MM},0} = T_0.$$

No segundo ponto:

$$T_{\text{MM},1} = \frac{T_0 + T_1}{2}.$$

A partir do terceiro ponto, a janela passa a conter as três amostras definidas por N :

$$T_{\text{MM},k} = \frac{T_k + T_{k-1} + T_{k-2}}{3}, \quad k \geq 2.$$

Portanto, para $N = 3$ e `min_periods=1`, o número de amostras utilizadas no cálculo evolui no início da série da seguinte forma:

$$1, \quad 2, \quad 3, \quad 3, \quad 3, \quad \dots$$

Após o terceiro ponto, a janela permanece com três amostras e se desloca ao longo da série à medida que novas medições são disponibilizadas.

Esse comportamento corresponde ao procedimento de inicialização adotado neste exercício e permite obter um valor filtrado para todos os instantes de medição, sem introduzir valores NaN no início da série.

4.7 Verificação dos primeiros resultados

Os primeiros valores calculados pelo Python deverão ser aproximadamente:

<code>tempo_s</code>	<code>sensor_ruidoso_C</code>	<code>sensor_referencia_C</code>	<code>media_movel_C</code>
0	0	25.5	25.0
1	1	26.2	25.1

2	2	24.8	25.0	25.500
3	3	27.0	25.0	26.000
4	4	23.9	25.0	25.233

Os valores apresentados pelo Python podem ser verificados diretamente a partir do procedimento utilizado no cálculo da média móvel. Essa verificação permite relacionar cada resultado apresentado na coluna `media_movel_C` às amostras utilizadas em seu cálculo.

No primeiro ponto, existe apenas uma amostra disponível:

$$T_{\text{MM},0} = T_0 = 25,50^\circ\text{C}.$$

No segundo ponto, existem duas amostras disponíveis:

$$T_{\text{MM},1} = \frac{T_0 + T_1}{2} = \frac{25,5 + 26,2}{2} = 25,85^\circ\text{C}.$$

No terceiro ponto, a primeira janela completa de três amostras já está disponível:

$$T_{\text{MM},2} = \frac{T_0 + T_1 + T_2}{3} = \frac{25,5 + 26,2 + 24,8}{3} = 25,50^\circ\text{C}.$$

Para o quarto ponto, a janela se desloca uma posição:

$$T_{\text{MM},3} = \frac{T_1 + T_2 + T_3}{3} = \frac{26,2 + 24,8 + 27,0}{3} = 26,00^\circ\text{C}.$$

No ponto seguinte:

$$T_{\text{MM},4} = \frac{T_2 + T_3 + T_4}{3} = \frac{24,8 + 27,0 + 23,9}{3} \approx 25,23^\circ\text{C}.$$

Os valores obtidos manualmente coincidem com aqueles calculados pelo Python. Dessa forma, é possível identificar claramente a origem dos resultados apresentados na coluna `media_movel_C` e relacioná-los às respectivas amostras utilizadas em cada janela.

Essa comparação entre o desenvolvimento manual e o resultado computacional é importante para compreender o funcionamento do método `rolling()`. O Python automatiza o mesmo procedimento desenvolvido anteriormente: seleciona as amostras pertencentes à janela, desloca essa janela à medida que novos pontos são considerados e calcula as médias correspondentes.

4.8 Interpretação do efeito da média móvel

Considere, por exemplo, a medição realizada no instante:

$$t_3 = 3\text{ s}.$$

O sensor ruidoso fornece:

$$T_3 = 27,0^\circ\text{C},$$

enquanto a média móvel fornece:

$$T_{MM,3} = 26,0^\circ\text{C}.$$

O valor filtrado não depende exclusivamente da medição atual. Ele incorpora também informações das duas medições anteriores:

$$T_1 = 26,2^\circ\text{C}$$

e

$$T_2 = 24,8^\circ\text{C}.$$

Consequentemente, uma alteração mais intensa em uma única amostra tende a ter seu efeito reduzido pela presença das demais amostras da janela. É esse mecanismo que produz a suavização observada no sinal.

Entretanto, essa propriedade também possui uma consequência importante. Como o valor filtrado depende de medições anteriores, o filtro apresenta **memória**.

Se a temperatura do processo sofrer uma mudança rápida, as amostras anteriores continuarão participando temporariamente do cálculo da média móvel. Dessa forma, o sinal filtrado poderá responder mais lentamente à nova condição.

Portanto, a escolha de N não deve ser realizada apenas buscando a maior suavização possível. Em uma aplicação real de Instrumentação, também devem ser consideradas a dinâmica do processo e a finalidade para a qual o sinal filtrado será utilizado.

5. Aplicação do filtro exponencial

A média móvel apresentada anteriormente realiza a suavização do sinal utilizando um conjunto de amostras pertencentes a uma janela de tamanho N .

Outra estratégia utilizada para suavizar séries de dados é a **filtragem exponencial**. Diferentemente da média móvel, na qual as amostras pertencentes à janela recebem o mesmo peso no cálculo, o filtro exponencial atualiza recursivamente o valor filtrado combinando:

- a medição atual;
- o valor filtrado obtido no instante anterior.

Uma forma de representar matematicamente esse procedimento é:

$$T_{F,k} = \alpha T_k + (1 - \alpha) T_{F,k-1}$$

em que:

- $T_{F,k}$ representa o valor filtrado no instante k ;

- T_k representa a medição atual do sensor;
- $T_{F,k-1}$ representa o valor filtrado no instante anterior;
- α representa o fator de suavização.

O parâmetro α deve satisfazer:

$$0 < \alpha \leq 1$$

e exerce influência direta sobre o comportamento do filtro.

5.1 Significado do parâmetro α

A equação utilizada para o filtro exponencial é:

$$T_{F,k} = \alpha T_k + (1 - \alpha) T_{F,k-1}.$$

Nessa expressão, o parâmetro

$$\alpha$$

determina o peso atribuído à medição atual, enquanto

$$1 - \alpha$$

determina o peso atribuído ao valor filtrado anterior.

Se α assumir um valor relativamente pequeno, o filtro atribuirá menor peso à medição atual e maior peso ao histórico representado pelo valor filtrado anterior.

Consequentemente, teremos maior suavização do sinal, porém uma resposta potencialmente mais lenta às mudanças da variável medida.

De maneira qualitativa:

$$\alpha \text{ pequeno} \longrightarrow \text{maior suavização e maior influência do histórico.}$$

Por outro lado, quando α aumenta, a medição atual passa a exercer maior influência sobre o resultado:

$$\alpha \text{ grande} \longrightarrow \text{menor suavização e resposta mais rápida.}$$

No limite, quando:

$$\alpha = 1,$$

a equação do filtro torna-se:

$$T_{F,k} = T_k.$$

Nesse caso, o valor filtrado é exatamente igual à medição atual e, conseqüentemente, não ocorre suavização.

Neste exercício será adotado:

$$\alpha = 0,30$$

Portanto:

$$1 - \alpha = 0,70.$$

A equação utilizada passa a ser:

$$T_{F,k} = 0,30T_k + 0,70T_{F,k-1}$$

Isso significa que cada novo valor filtrado recebe 30% de contribuição da medição atual e 70% de contribuição do valor filtrado anterior.

5.2 Condição inicial do filtro

A equação do filtro exponencial é recursiva:

$$T_{F,k} = \alpha T_k + (1 - \alpha)T_{F,k-1}.$$

Portanto, para calcular o valor filtrado no instante atual, é necessário conhecer o valor filtrado no instante anterior.

Isso produz uma questão importante no início da série:

como calcular $T_{F,0}$ se ainda não existe $T_{F,-1}$?

É necessário estabelecer uma **condição inicial** para o filtro.

Neste exercício será adotada uma escolha simples:

$$T_{F,0} = T_0$$

ou seja, o primeiro valor filtrado será igual à primeira medição disponível.

Como:

$$T_0 = 25,5^\circ\text{C},$$

temos:

$$T_{F,0} = 25,5^\circ\text{C}$$

A partir dessa condição inicial, os demais valores podem ser calculados recursivamente.

5.3 Cálculo manual do segundo ponto

No instante:

$$t_1 = 1 \text{ s},$$

a medição do sensor ruidoso é:

$$T_1 = 26,2^\circ\text{C}.$$

O valor filtrado anterior é:

$$T_{F,0} = 25,5^\circ\text{C}.$$

Utilizando:

$$\alpha = 0,30,$$

temos:

$$T_{F,1} = 0,30T_1 + 0,70T_{F,0}.$$

Substituindo os valores:

$$T_{F,1} = 0,30(26,2) + 0,70(25,5).$$

Portanto:

$$T_{F,1} = 7,86 + 17,85,$$

resultando em:

$$\boxed{T_{F,1} = 25,71^\circ\text{C}}$$

Observe que a medição atual é:

$$T_1 = 26,2^\circ\text{C},$$

enquanto o valor filtrado é:

$$T_{F,1} = 25,71^\circ\text{C}.$$

Essa diferença ocorre porque o filtro não utiliza apenas a medição atual. O novo valor filtrado também incorpora a informação acumulada no valor filtrado anterior.

5.4 Cálculo manual do terceiro ponto

No instante:

$$t_2 = 2\text{ s},$$

a nova medição é:

$$T_2 = 24,8^\circ\text{C}.$$

Agora o valor anterior utilizado pelo filtro não é mais a primeira medição, mas o resultado filtrado obtido no passo anterior:

$$T_{F,1} = 25,71^\circ\text{C}.$$

Assim:

$$T_{F,2} = 0,30T_2 + 0,70T_{F,1}.$$

Substituindo:

$$T_{F,2} = 0,30(24,8) + 0,70(25,71).$$

Portanto:

$$T_{F,2} = 7,44 + 17,997,$$

e:

$$T_{F,2} = 25,437^\circ\text{C}$$

ou, com duas casas decimais:

$$T_{F,2} \approx 25,44^\circ\text{C}$$

Observe um aspecto importante. Entre os instantes t_1 e t_2 , a medição do sensor ruidoso passou de:

$$T_1 = 26,2^\circ\text{C}$$

para:

$$T_2 = 24,8^\circ\text{C}.$$

Portanto, a variação observada no sinal original foi:

$$\Delta T = T_2 - T_1 = 24,8 - 26,2 = -1,4^\circ\text{C}.$$

No sinal filtrado, os valores correspondentes passaram de:

$$T_{F,1} = 25,71\text{ }^{\circ}\text{C}$$

para:

$$T_{F,2} = 25,437\text{ }^{\circ}\text{C}.$$

Assim, a variação do sinal filtrado foi:

$$\Delta T_F = T_{F,2} - T_{F,1} = 25,437 - 25,71 = -0,273\text{ }^{\circ}\text{C}.$$

Comparando os dois resultados, observa-se que uma variação de $-1,4\text{ }^{\circ}\text{C}$ no sinal original produziu, nesse passo, uma variação de apenas $-0,273\text{ }^{\circ}\text{C}$ no sinal filtrado.

Esse resultado evidencia o efeito de suavização do filtro exponencial. A nova medição influencia o resultado, mas seu efeito é atenuado pela contribuição do valor filtrado anterior.

5.5 Cálculo manual do quarto ponto

No instante:

$$t_3 = 3\text{ s},$$

o sensor fornece:

$$T_3 = 27,0\text{ }^{\circ}\text{C}.$$

O valor filtrado anterior é:

$$T_{F,2} = 25,437\text{ }^{\circ}\text{C}.$$

Logo:

$$T_{F,3} = 0,30T_3 + 0,70T_{F,2}.$$

Substituindo os valores:

$$T_{F,3} = 0,30(27,0) + 0,70(25,437).$$

Calculando cada parcela:

$$0,30(27,0) = 8,10$$

e:

$$0,70(25,437) = 17,8059.$$

Portanto:

$$T_{F,3} = 8,10 + 17,8059,$$

resultando em:

$$T_{F,3} = 25,9059^{\circ}\text{C}$$

ou, com duas casas decimais:

$$T_{F,3} \approx 25,91^{\circ}\text{C}$$

Novamente, é possível observar o efeito da filtragem comparando a variação do sinal original com a variação do sinal filtrado.

Entre os instantes t_2 e t_3 , a medição do sensor ruidoso passou de:

$$T_2 = 24,8^{\circ}\text{C}$$

para:

$$T_3 = 27,0^{\circ}\text{C}.$$

Portanto, a variação observada no sinal original foi:

$$\Delta T = T_3 - T_2 = 27,0 - 24,8 = 2,2^{\circ}\text{C}.$$

No sinal filtrado, os valores correspondentes passaram de:

$$T_{F,2} = 25,437^{\circ}\text{C}$$

para:

$$T_{F,3} = 25,9059^{\circ}\text{C}.$$

Assim, a variação do sinal filtrado foi:

$$\Delta T_F = T_{F,3} - T_{F,2} = 25,9059 - 25,437 = 0,4689^{\circ}\text{C}.$$

Comparando os dois resultados, observa-se que uma variação de $2,2^{\circ}\text{C}$ no sinal original produziu, nesse passo, uma variação de apenas $0,4689^{\circ}\text{C}$ no sinal filtrado.

Esse comportamento evidencia novamente o efeito de suavização introduzido pelo filtro exponencial. A medição atual participa do cálculo, mas seu efeito sobre o resultado é moderado pela contribuição do valor filtrado anterior.

5.6 Por que o filtro é denominado exponencial?

À primeira vista, a expressão:

$$T_{F,k} = \alpha T_k + (1 - \alpha)T_{F,k-1}$$

parece utilizar apenas a medição atual e o valor filtrado anterior.

Entretanto, o valor $T_{F,k-1}$ já contém informações provenientes das medições anteriores.

Por exemplo:

$$T_{F,k-1} = \alpha T_{k-1} + (1 - \alpha)T_{F,k-2}.$$

Substituindo essa expressão na equação original:

$$T_{F,k} = \alpha T_k + (1 - \alpha) [\alpha T_{k-1} + (1 - \alpha)T_{F,k-2}].$$

Distribuindo os termos:

$$T_{F,k} = \alpha T_k + \alpha(1 - \alpha)T_{k-1} + (1 - \alpha)^2 T_{F,k-2}.$$

O termo $T_{F,k-2}$, por sua vez, também contém informações das medições anteriores. Ao continuar sucessivamente esse desenvolvimento, surgem termos envolvendo:

$$(1 - \alpha), \quad (1 - \alpha)^2, \quad (1 - \alpha)^3, \quad \dots$$

Assim, a influência das informações mais antigas diminui progressivamente segundo potências sucessivas de $(1 - \alpha)$.

Para o filtro utilizado neste exercício:

$$\alpha = 0,30,$$

e, portanto:

$$1 - \alpha = 0,70.$$

Consequentemente, as potências associadas à influência das informações anteriores assumem valores como:

$$(0,70)^1 = 0,70,$$

$$(0,70)^2 = 0,49,$$

$$(0,70)^3 = 0,343,$$

$$(0,70)^4 = 0,2401,$$

e assim sucessivamente.

Esses valores mostram que a influência das informações mais antigas não desaparece imediatamente. Ela permanece incorporada ao valor filtrado, porém com uma contribuição que diminui progressivamente à medida que novas medições são processadas.

É essa redução dos pesos segundo potências sucessivas de $(1 - \alpha)$ que dá origem à denominação **suavização exponencial**.

5.7 Implementação do filtro exponencial utilizando Python

O Pandas disponibiliza o método `ewm()` para realizar operações de média ponderada exponencial.

Neste exercício foi adotado:

$$\alpha = 0,30.$$

Portanto, o mesmo valor utilizado nos cálculos manuais será empregado na implementação computacional.

O filtro exponencial pode ser aplicado à coluna `sensor_ruidoso_C` da seguinte forma:

```
##%
# -----
# 6. Aplicação do filtro exponencial
# -----

# Fator de suavização
alpha = 0.30

# Cálculo do sinal filtrado
tabela["filtro_exponencial_C"] = (
    tabela["sensor_ruidoso_C"]
    .ewm(alpha=alpha, adjust=False)
    .mean()
)

# Visualização dos resultados
print(
    tabela[
        [
            "tempo_s",
            "sensor_ruidoso_C",
```

```
"sensor_referencia_C",
"filtro_exponencial_C"
]
]
)
```

No comando:

```
.ewm(alpha=alpha, adjust=False)
```

o argumento:

```
alpha=alpha
```

define o fator de suavização utilizado pelo filtro. Como anteriormente foi definido:

```
alpha = 0.30
```

o Pandas utilizará:

$$\alpha = 0,30.$$

Já o argumento:

```
adjust=False
```

faz com que o cálculo seja realizado de forma recursiva, seguindo a expressão utilizada nos cálculos manuais:

$$T_{F,k} = \alpha T_k + (1 - \alpha) T_{F,k-1}$$

com o primeiro valor filtrado inicializado a partir da primeira medição da série:

$$T_{F,0} = T_0$$

No conjunto de dados deste exercício:

$$T_0 = 25,5^\circ\text{C},$$

portanto:

$$T_{F,0} = 25,5^\circ\text{C}.$$

A partir desse valor inicial, os demais valores são calculados recursivamente. Assim, para o segundo ponto, o Python realiza numericamente a operação:

$$T_{F,1} = 0,30T_1 + 0,70T_{F,0},$$

que corresponde ao cálculo manual:

$$T_{F,1} = 0,30(26,2) + 0,70(25,5) = 25,71 \text{ }^{\circ}\text{C}.$$

Para o ponto seguinte:

$$T_{F,2} = 0,30T_2 + 0,70T_{F,1},$$

e, substituindo os valores:

$$T_{F,2} = 0,30(24,8) + 0,70(25,71) = 25,437 \text{ }^{\circ}\text{C}.$$

Dessa forma, existe correspondência direta entre o procedimento desenvolvido manualmente e a implementação computacional. O método `ewm()` automatiza a aplicação sucessiva da mesma relação recursiva utilizada nos cálculos anteriores.

5.8 Verificação dos primeiros resultados

Os primeiros valores calculados pelo Python deverão ser aproximadamente:

tempo_s	sensor_ruidoso_C	sensor_referencia_C	filtro_exponencial_C	
0	0	25.5	25.0	25.500
1	1	26.2	25.1	25.710
2	2	24.8	25.0	25.437
3	3	27.0	25.0	25.906
4	4	23.9	25.0	25.304

Os primeiros resultados apresentados pelo Python podem ser comparados diretamente com os valores determinados manualmente.

Para o primeiro ponto, foi estabelecida a condição inicial:

$$T_{F,0} = T_0 = 25,50 \text{ }^{\circ}\text{C}.$$

Para o segundo ponto:

$$T_{F,1} = 0,30T_1 + 0,70T_{F,0}$$

e, substituindo os valores:

$$T_{F,1} = 0,30(26,2) + 0,70(25,5) = 25,71 \text{ }^{\circ}\text{C}.$$

Para o terceiro ponto:

$$T_{F,2} = 0,30T_2 + 0,70T_{F,1}$$

e:

$$T_{F,2} = 0,30(24,8) + 0,70(25,71) = 25,437^{\circ}\text{C}.$$

Para o quarto ponto:

$$T_{F,3} = 0,30T_3 + 0,70T_{F,2}$$

e:

$$T_{F,3} = 0,30(27,0) + 0,70(25,437) = 25,9059^{\circ}\text{C}.$$

Com três casas decimais:

$$T_{F,3} \approx 25,906^{\circ}\text{C}.$$

O quinto valor apresentado pelo Python ainda pode ser verificado aplicando o mesmo procedimento. Para:

$$t_4 = 4\text{ s},$$

a medição do sensor ruidoso é:

$$T_4 = 23,9^{\circ}\text{C}.$$

O valor filtrado anterior é:

$$T_{F,3} = 25,9059^{\circ}\text{C}.$$

Portanto:

$$T_{F,4} = 0,30T_4 + 0,70T_{F,3}.$$

Substituindo os valores:

$$T_{F,4} = 0,30(23,9) + 0,70(25,9059).$$

Calculando cada parcela:

$$0,30(23,9) = 7,17$$

e:

$$0,70(25,9059) = 18,13413.$$

Logo:

$$T_{F,4} = 7,17 + 18,13413,$$

resultando em:

$$T_{F,4} = 25,30413^{\circ}\text{C}$$

ou, com três casas decimais:

$$T_{F,4} \approx 25,304^{\circ}\text{C}$$

Os valores obtidos manualmente coincidem com aqueles apresentados pelo Python na coluna `filtro_exponencial_C`.

Essa concordância permite verificar que a implementação computacional reproduz a relação recursiva desenvolvida anteriormente. Para cada nova medição, o Python combina a medição atual com o valor filtrado anterior, utilizando os pesos definidos por $\alpha = 0,30$ e $1 - \alpha = 0,70$.

5.9 Comparação conceitual com a média móvel

Neste ponto, já foram aplicados dois métodos de suavização ao mesmo sinal: a média móvel e o filtro exponencial.

Na média móvel com:

$$N = 3,$$

cada valor, após o preenchimento completo da janela, é calculado utilizando três medições:

$$T_{\text{MM},k} = \frac{T_k + T_{k-1} + T_{k-2}}{3}.$$

As três amostras pertencentes à janela recebem o mesmo peso:

$$\frac{1}{3}.$$

Isso significa que, após o preenchimento completo da janela, o valor filtrado depende apenas da medição atual e das duas medições imediatamente anteriores. À medida que a janela se desloca, a amostra mais antiga deixa de participar do cálculo.

No filtro exponencial com:

$$\alpha = 0,30,$$

temos:

$$T_{F,k} = 0,30T_k + 0,70T_{F,k-1}.$$

Nesse caso, a medição atual participa diretamente do cálculo com peso igual a 0,30, enquanto o histórico das medições anteriores encontra-se incorporado ao valor filtrado $T_{F,k-1}$.

Como observado anteriormente, ao desenvolver recursivamente essa expressão, a influência das informações anteriores diminui progressivamente segundo potências sucessivas de:

$$1 - \alpha.$$

Para:

$$\alpha = 0,30,$$

temos:

$$1 - \alpha = 0,70.$$

Portanto, diferentemente da média móvel, na qual uma amostra deixa de participar do cálculo quando sai da janela, no filtro exponencial a influência das informações anteriores é reduzida progressivamente à medida que novas medições são processadas.

Embora os dois métodos tenham como objetivo suavizar as oscilações presentes no sinal, eles não realizam a mesma operação matemática.

De forma resumida:

Média móvel $\longrightarrow$ janela finita de amostras
Filtro exponencial $\longrightarrow$ atualização recursiva do sinal filtrado

Essa diferença será importante na interpretação dos resultados, pois os dois filtros podem produzir respostas distintas mesmo quando aplicados ao mesmo conjunto de medições.

5.10 Influência de α sobre o sinal filtrado

É importante compreender que:

$$\alpha = 0,30$$

não constitui um valor universal ou necessariamente ideal para qualquer aplicação.

Esse valor foi adotado neste exercício para permitir uma visualização clara do efeito da filtragem e, ao mesmo tempo, possibilitar o desenvolvimento manual dos primeiros pontos.

Se utilizássemos, por exemplo:

$$\alpha = 0,10,$$

a medição atual teria 10% de participação direta na atualização, enquanto o valor filtrado anterior teria peso de 90%:

$$T_{F,k} = 0,10T_k + 0,90T_{F,k-1}.$$

Nesse caso, o sinal tenderia a apresentar maior suavização e maior influência do histórico. Como consequência, também tenderia a responder mais lentamente às mudanças presentes nas medições.

Por outro lado, para:

$$\alpha = 0,80,$$

teríamos:

$$T_{F,k} = 0,80T_k + 0,20T_{F,k-1}.$$

Nesse caso, a medição atual teria maior influência sobre o resultado e o sinal filtrado tenderia a acompanhar mais rapidamente as variações presentes nos dados, produzindo menor suavização.

Assim como ocorreu com o parâmetro N da média móvel, a escolha de α envolve um compromisso entre:

suavização do sinal	e	velocidade de resposta
---------------------	---	------------------------

Portanto, aumentar ou diminuir α não significa simplesmente tornar o filtro “melhor” ou “pior”. A escolha depende do comportamento que se deseja obter para o sinal filtrado.

Em aplicações reais, essa escolha deve considerar a dinâmica do processo, as características das perturbações presentes no sinal, a frequência de aquisição dos dados e a finalidade para a qual a medição será utilizada.

6. Comparação gráfica entre o sinal original e os sinais filtrados

Após a aplicação dos dois filtros, o DataFrame contém diferentes representações da temperatura analisada:

- a indicação original do sensor ruidoso;
- a indicação do sensor adotado como referência;
- o sinal obtido pelo filtro de média móvel;
- o sinal obtido pelo filtro exponencial.

A representação gráfica dessas informações permite observar de maneira direta o efeito produzido pelos filtros sobre as oscilações presentes no sinal original.

Inicialmente, os dois métodos serão analisados separadamente. Essa estratégia permite observar com maior clareza o comportamento de cada filtro antes de realizar uma comparação conjunta entre o sinal original, a referência e os dois sinais filtrados.

6.1 Comparação entre o sinal original e a média móvel

O primeiro gráfico apresenta simultaneamente:

- a indicação do sensor ruidoso;
- a indicação do sensor de referência;
- o sinal obtido pela média móvel com $N = 3$.

Essa representação permite observar diretamente como a aplicação da média móvel modifica o comportamento do sinal original ao longo do tempo.

O gráfico pode ser construído utilizando o seguinte código:

```
#%%  
# -----  
# 7. Comparação do sinal original com a média móvel  
# -----  
  
plt.figure(figsize=(10, 6))  
  
# Sinal original  
plt.plot(  
    tabela["tempo_s"],  
    tabela["sensor_ruidoso_C"],  
    color="black",  
    linestyle="-",  
    marker="o",  
    label="Sensor ruidoso"  
)  
  
# Sinal de referência  
plt.plot(  
    tabela["tempo_s"],  
    tabela["sensor_referencia_C"],  
    color="black",  
    linestyle="--",  
    marker="s",  
    label="Sensor de referência"  
)  
  
# Média móvel  
plt.plot(  

```

```

tabela["tempo_s"],
tabela["media_movel_C"],
color="black",
linestyle="-.",
marker="^",
label="Média móvel (N = 3)"
)

# Identificação dos eixos
plt.xlabel("Tempo (s)")
plt.ylabel("Temperatura (°C)")

# Título
plt.title("Efeito da média móvel sobre o sinal de temperatura")

# Grade e legenda
plt.grid(True)
plt.legend()

# Ajuste automático do espaçamento
plt.tight_layout()

# Exibição do gráfico
plt.show()

# Nome sugerido para salvar a figura:
# efeito-media-movel-sinal-temperatura

```

A figura 12 mostra a comparação entre o sinal original, a indicação de referência e o sinal obtido após a aplicação da média móvel com uma janela de três amostras.

Figura 12: Comparação entre a indicação original do sensor ruidoso, a indicação do sensor de referência e o sinal obtido após a aplicação do filtro de média móvel com $N = 3$.

Ao observar o gráfico, nota-se que o sinal original apresenta oscilações sucessivas em relação à indicação fornecida pelo sensor de referência.

A média móvel reduz parte dessas oscilações porque cada novo valor filtrado, após o preenchimento completo da janela, é calculado utilizando três medições:

$$T_{MM,k} = \frac{T_k + T_{k-1} + T_{k-2}}{3}.$$

Consequentemente, uma variação acentuada presente em uma única medição não é transferida integralmente para o valor filtrado. Seu efeito é combinado com os valores das outras

amostras pertencentes à janela.

Por exemplo, no instante:

$$t_3 = 3\text{ s},$$

o sensor ruidoso fornece:

$$T_3 = 27,0^\circ\text{C},$$

enquanto a média móvel fornece:

$$T_{\text{MM},3} = 26,0^\circ\text{C}.$$

No instante seguinte:

$$t_4 = 4\text{ s},$$

o sensor ruidoso passa para:

$$T_4 = 23,9^\circ\text{C},$$

enquanto o valor correspondente da média móvel é:

$$T_{\text{MM},4} \approx 25,23^\circ\text{C}.$$

Esses valores ajudam a compreender o comportamento observado no gráfico. Enquanto o sinal original passa rapidamente de $27,0^\circ\text{C}$ para $23,9^\circ\text{C}$, a média móvel apresenta uma variação consideravelmente menor.

É importante observar, entretanto, que o sinal filtrado não precisa coincidir exatamente com a referência em todos os instantes. O objetivo da média móvel é suavizar as oscilações presentes no sinal de entrada, e não substituir diretamente os valores medidos pelos valores fornecidos pelo sensor de referência.

Portanto, a observação do gráfico permite avaliar qualitativamente o efeito da filtragem, mas ainda não permite concluir, por si só, quanto o erro em relação à referência foi reduzido.

Essa avaliação será realizada posteriormente de forma quantitativa, calculando o erro do sinal filtrado em relação ao sensor de referência.

6.2 Comparação entre o sinal original e o filtro exponencial

Podemos realizar a mesma análise para o filtro exponencial.

Neste caso, serão representados:

- a indicação original do sensor ruidoso;
- a indicação do sensor de referência;

- o sinal filtrado utilizando $\alpha = 0,30$.

Essa representação permite observar diretamente como o filtro exponencial modifica o comportamento do sinal original ao longo do tempo.

O gráfico pode ser construído utilizando o seguinte código:

```
###
# -----
# 8. Comparação do sinal original com o
#    filtro exponencial
# -----

plt.figure(figsize=(10, 6))

# Sinal original
plt.plot(
    tabela["tempo_s"],
    tabela["sensor_ruidoso_C"],
    color="black",
    linestyle="-",
    marker="o",
    label="Sensor ruidoso"
)

# Sinal de referência
plt.plot(
    tabela["tempo_s"],
    tabela["sensor_referencia_C"],
    color="black",
    linestyle="--",
    marker="s",
    label="Sensor de referência"
)

# Filtro exponencial
plt.plot(
    tabela["tempo_s"],
    tabela["filtro_exponencial_C"],
    color="black",
    linestyle="-. ",
    marker="^",
    label="Filtro exponencial (alpha = 0.30)"
)
```

```

)

# Identificação dos eixos
plt.xlabel("Tempo (s)")
plt.ylabel("Temperatura (°C)")

# Título
plt.title("Efeito do filtro exponencial sobre o sinal de temperatura")

# Grade e legenda
plt.grid(True)
plt.legend()

# Ajuste automático do espaçamento
plt.tight_layout()

# Exibição do gráfico
plt.show()

# Nome sugerido para salvar a figura:
# efeito-filtro-exponencial-sinal-temperatura

```

A figura 13 mostra a comparação entre o sinal original, a indicação de referência e o resultado obtido após a aplicação do filtro exponencial.

Figura 13: Comparação entre a indicação original do sensor ruidoso, a indicação do sensor de referência e o sinal obtido após a aplicação do filtro exponencial com fator de suavização $\alpha = 0,30$.

Assim como ocorreu com a média móvel, o filtro exponencial reduz a influência das oscilações mais intensas presentes no sinal original.

Entretanto, o mecanismo utilizado é diferente.

No filtro exponencial:

$$T_{F,k} = \alpha T_k + (1 - \alpha) T_{F,k-1}.$$

Para:

$$\alpha = 0,30,$$

temos:

$$T_{F,k} = 0,30T_k + 0,70T_{F,k-1}.$$

Portanto, a medição atual participa diretamente da atualização com peso igual a 0,30, enquanto o valor filtrado anterior participa com peso igual a 0,70. Como esse valor filtrado anterior já contém informações das medições anteriores, o histórico do sinal permanece incorporado recursivamente ao resultado.

O efeito desse procedimento pode ser relacionado diretamente aos valores calculados anteriormente.

No instante:

$$t_2 = 2 \text{ s},$$

o sensor ruidoso fornece:

$$T_2 = 24,8^\circ\text{C},$$

enquanto o filtro exponencial fornece:

$$T_{F,2} = 25,437^\circ\text{C}.$$

No instante seguinte:

$$t_3 = 3 \text{ s},$$

a indicação do sensor ruidoso aumenta para:

$$T_3 = 27,0^\circ\text{C},$$

enquanto o sinal filtrado passa para:

$$T_{F,3} = 25,9059^\circ\text{C}.$$

Em seguida, para:

$$t_4 = 4 \text{ s},$$

a indicação original diminui para:

$$T_4 = 23,9^\circ\text{C},$$

enquanto o filtro exponencial fornece:

$$T_{F,4} = 25,30413^\circ\text{C}.$$

Esses valores ajudam a compreender o comportamento observado no gráfico. Enquanto o sinal original apresenta alterações relativamente intensas entre pontos consecutivos, o sinal filtrado apresenta variações menores devido à contribuição do valor filtrado anterior em cada

nova atualização.

É importante observar novamente que a finalidade do filtro não é fazer com que o sinal resultante coincida necessariamente com o sensor de referência em todos os instantes. O filtro atua sobre o sinal original com o objetivo de suavizar suas oscilações.

Portanto, assim como ocorreu na análise da média móvel, a observação do gráfico permite avaliar qualitativamente o efeito da filtragem, mas ainda não permite determinar quantitativamente se houve redução do erro em relação à referência.

Essa avaliação será realizada posteriormente por meio do cálculo dos erros dos sinais filtrados.

6.3 Comparação conjunta dos dois filtros

Depois de analisar separadamente cada método, torna-se interessante representar os dois sinais filtrados em um mesmo gráfico.

Nesse caso, o objetivo não é apenas verificar se houve suavização, mas observar se a média móvel e o filtro exponencial apresentam comportamentos diferentes diante das mesmas oscilações do sinal original.

Para evitar excesso de informações visuais, neste gráfico serão representados apenas o sinal original e os dois sinais filtrados. A indicação do sensor de referência não será incluída nesta etapa, pois o objetivo específico é comparar o comportamento dos métodos de filtragem.

O gráfico pode ser construído utilizando o seguinte código:

```
##%
# -----
# 9. Comparação conjunta dos filtros
# -----

plt.figure(figsize=(10, 6))

# Sinal original
plt.plot(
    tabela["tempo_s"],
    tabela["sensor_ruidoso_C"],
    color="black",
    linestyle=":",
    marker="o",
    label="Sensor ruidoso"
)

# Média móvel
plt.plot(
    tabela["tempo_s"],
```

```

tabela["media_movel_C"],
color="black",
linestyle="--",
marker="s",
label="Média móvel (N = 3)"
)

# Filtro exponencial
plt.plot(
tabela["tempo_s"],
tabela["filtro_exponencial_C"],
color="black",
linestyle="-",
marker="^",
label="Filtro exponencial (alpha = 0.30)"
)

# Identificação dos eixos
plt.xlabel("Tempo (s)")
plt.ylabel("Temperatura (°C)")

# Título
plt.title("Comparação entre os métodos de filtragem digital")

# Grade e legenda
plt.grid(True)
plt.legend()

# Ajuste automático do espaçamento
plt.tight_layout()

# Exibição do gráfico
plt.show()

# Nome sugerido para salvar a figura:
# comparacao-metodos-filtragem-digital

```

A figura 14 permite comparar diretamente o comportamento dos dois métodos de filtragem aplicados ao mesmo conjunto de medições.

A comparação gráfica permite observar que os dois métodos reduzem as oscilações presentes nas medições, mas produzem sinais filtrados diferentes.

Figura 14: Comparação entre o sinal original do sensor ruidoso e os sinais obtidos pelos filtros de média móvel, com $N = 3$, e exponencial, com $\alpha = 0,30$.

Isso ocorre porque a média móvel e o filtro exponencial utilizam mecanismos matemáticos distintos para incorporar as informações provenientes das medições anteriores.

Na média móvel com:

$$N = 3,$$

após o preenchimento completo da janela, o valor filtrado é calculado por:

$$T_{MM,k} = \frac{T_k + T_{k-1} + T_{k-2}}{3}.$$

Portanto, as três amostras pertencentes à janela recebem pesos iguais:

$$\frac{1}{3}, \quad \frac{1}{3}, \quad \frac{1}{3}.$$

Quando uma nova medição é adquirida, a janela se desloca e a amostra mais antiga deixa de participar do cálculo.

No filtro exponencial utilizado neste exercício:

$$T_{F,k} = 0,30T_k + 0,70T_{F,k-1}.$$

Nesse caso, a medição atual participa diretamente com peso 0,30, enquanto o valor filtrado anterior participa com peso 0,70. Como esse valor anterior já contém informações provenientes das medições anteriores, o histórico permanece incorporado recursivamente ao sinal filtrado, com influência progressivamente reduzida.

Essas diferenças matemáticas explicam por que as duas curvas filtradas não coincidem, embora tenham sido obtidas a partir do mesmo sinal original. A observação do gráfico permite comparar qualitativamente o comportamento dos dois métodos. Entretanto, não se deve concluir apenas pela aparência das curvas qual deles produz maior aproximação em relação à referência.

Uma curva visualmente mais suave não significa, necessariamente, que suas indicações estejam mais próximas dos valores fornecidos pelo sensor de referência. Para avaliar quantitativamente o efeito da filtragem, o próximo passo consiste em calcular os erros dos dois sinais filtrados em relação à referência e comparar esses resultados com o erro determinado anteriormente para o sinal original.

7. Comparação dos erros antes e depois da filtragem

A análise gráfica realizada anteriormente permitiu observar qualitativamente o efeito produzido pelos filtros sobre o sinal original. Entretanto, uma curva visualmente mais suave não significa necessariamente que os valores filtrados estejam mais próximos da indicação

fornecida pelo sensor de referência.

Para avaliar quantitativamente o efeito da filtragem, serão calculados os erros absolutos correspondentes a três sinais:

- sinal original do sensor ruidoso;
- sinal obtido pelo filtro de média móvel;
- sinal obtido pelo filtro exponencial.

O erro absoluto do sinal original já foi definido anteriormente por:

$$E_{\text{abs},k} = |T_{\text{ruidoso},k} - T_{\text{referencia},k}|$$

Agora, o mesmo procedimento será aplicado aos sinais filtrados.

7.1 Erro absoluto após a aplicação da média móvel

Para o sinal obtido pelo filtro de média móvel, o erro absoluto em cada instante pode ser definido por:

$$E_{\text{MM},k} = |T_{\text{MM},k} - T_{\text{referencia},k}|$$

em que:

$$T_{\text{MM},k}$$

representa o valor fornecido pela média móvel no instante k , enquanto:

$$T_{\text{referencia},k}$$

representa a indicação do sensor adotado como referência no mesmo instante.

Cálculo manual para o primeiro ponto

No primeiro instante:

$$t_0 = 0 \text{ s},$$

o valor da média móvel é:

$$T_{\text{MM},0} = 25,50^\circ\text{C},$$

enquanto a indicação do sensor de referência é:

$$T_{\text{referencia},0} = 25,0^\circ\text{C}.$$

Portanto:

$$E_{\text{MM},0} = |T_{\text{MM},0} - T_{\text{referencia},0}|.$$

Substituindo os valores:

$$E_{\text{MM},0} = |25,50 - 25,0|.$$

Logo:

$$E_{\text{MM},0} = 0,50\text{ }^{\circ}\text{C}$$

Cálculo manual para o segundo ponto

No instante:

$$t_1 = 1\text{ s},$$

o valor calculado pela média móvel é:

$$T_{\text{MM},1} = 25,85\text{ }^{\circ}\text{C}.$$

Nesse mesmo instante, a indicação de referência é:

$$T_{\text{referencia},1} = 25,1\text{ }^{\circ}\text{C}.$$

Assim:

$$E_{\text{MM},1} = |T_{\text{MM},1} - T_{\text{referencia},1}|.$$

Substituindo:

$$E_{\text{MM},1} = |25,85 - 25,1|.$$

Portanto:

$$E_{\text{MM},1} = 0,75\text{ }^{\circ}\text{C}$$

Cálculo manual para o terceiro ponto

No instante:

$$t_2 = 2\text{ s},$$

temos:

$$T_{\text{MM},2} = 25,50^\circ\text{C}$$

e:

$$T_{\text{referencia},2} = 25,0^\circ\text{C}.$$

O erro absoluto correspondente é:

$$E_{\text{MM},2} = |T_{\text{MM},2} - T_{\text{referencia},2}|.$$

Substituindo os valores:

$$E_{\text{MM},2} = |25,50 - 25,0|.$$

Logo:

$$E_{\text{MM},2} = 0,50^\circ\text{C}$$

Esses primeiros cálculos mostram como o erro do sinal filtrado é determinado. O procedimento é semelhante ao utilizado anteriormente para o sinal original, mas agora a comparação com a referência é realizada utilizando os valores produzidos pelo filtro de média móvel.

7.2 Erro absoluto após a aplicação do filtro exponencial

Para o filtro exponencial, o erro absoluto em cada instante será definido por:

$$E_{F,k} = |T_{F,k} - T_{\text{referencia},k}|$$

em que:

$$T_{F,k}$$

representa o valor fornecido pelo filtro exponencial no instante k .

Cálculo manual para o primeiro ponto

Como a condição inicial adotada para o filtro foi:

$$T_{F,0} = T_0 = 25,50^\circ\text{C},$$

e a indicação de referência nesse instante é:

$$T_{\text{referencia},0} = 25,0^\circ\text{C},$$

temos:

$$E_{F,0} = |T_{F,0} - T_{\text{referencia},0}|.$$

Substituindo:

$$E_{F,0} = |25,50 - 25,0|.$$

Portanto:

$$\boxed{E_{F,0} = 0,50^\circ\text{C}}$$

Cálculo manual para o segundo ponto

Para:

$$t_1 = 1\text{ s},$$

foi determinado anteriormente:

$$T_{F,1} = 25,71^\circ\text{C}.$$

A indicação do sensor de referência é:

$$T_{\text{referencia},1} = 25,1^\circ\text{C}.$$

Assim:

$$E_{F,1} = |T_{F,1} - T_{\text{referencia},1}|.$$

Substituindo os valores:

$$E_{F,1} = |25,71 - 25,1|.$$

Logo:

$$\boxed{E_{F,1} = 0,61^\circ\text{C}}$$

Cálculo manual para o terceiro ponto

No instante:

$$t_2 = 2\text{ s},$$

o valor calculado pelo filtro exponencial foi:

$$T_{F,2} = 25,437^\circ\text{C}.$$

A indicação de referência é:

$$T_{\text{referencia},2} = 25,0^{\circ}\text{C}.$$

Portanto:

$$E_{F,2} = |T_{F,2} - T_{\text{referencia},2}|.$$

Substituindo:

$$E_{F,2} = |25,437 - 25,0|.$$

Logo:

$$E_{F,2} = 0,437^{\circ}\text{C}$$

Os cálculos realizados para os primeiros pontos mostram que os erros dos sinais filtrados podem ser determinados utilizando exatamente o mesmo princípio empregado para o sinal original: calcula-se a magnitude da diferença entre o valor analisado e a indicação adotada como referência.

A partir dessas definições, o próximo passo consiste em realizar os cálculos para todos os pontos utilizando Python e adicionar os resultados ao DataFrame. Dessa forma, será possível comparar quantitativamente os erros do sinal original, da média móvel e do filtro exponencial.

7.3 Cálculo dos erros utilizando Python

Como os sinais obtidos pelos dois filtros já estão armazenados no DataFrame, os erros absolutos podem ser calculados diretamente a partir das respectivas colunas.

O erro absoluto do sinal original já foi calculado anteriormente e está armazenado na coluna:

`erro_original_C`

Agora serão criadas duas novas colunas:

- `erro_media_movel_C`, para armazenar o erro absoluto do sinal obtido pela média móvel;
- `erro_exponencial_C`, para armazenar o erro absoluto do sinal obtido pelo filtro exponencial.

As expressões utilizadas são:

$$E_{\text{MM},k} = |T_{\text{MM},k} - T_{\text{referencia},k}|$$

e:

$$E_{F,k} = |T_{F,k} - T_{\text{referencia},k}|.$$

Em Python, esses cálculos podem ser realizados utilizando a função `abs()` do NumPy:

```
#%%
# -----
# 10. Cálculo dos erros após a filtragem
# -----

# Erro absoluto da média móvel
tabela["erro_media_movel_C"] = np.abs(
tabela["media_movel_C"]
- tabela["sensor_referencia_C"]
)

# Erro absoluto do filtro exponencial
tabela["erro_exponencial_C"] = np.abs(
tabela["filtro_exponencial_C"]
- tabela["sensor_referencia_C"]
)

# Visualização dos resultados
print(
tabela[
[
"tempo_s",
"erro_original_C",
"erro_media_movel_C",
"erro_exponencial_C"
]
]
)
```

A operação é realizada elemento a elemento. Para cada instante de medição, o Python compara o valor correspondente de cada sinal com a indicação do sensor de referência.

Por exemplo, para:

$$t_1 = 1 \text{ s},$$

o valor da média móvel é:

$$T_{\text{MM},1} = 25,85^\circ\text{C},$$

enquanto a referência é:

$$T_{\text{referencia},1} = 25,1^\circ\text{C}.$$

Consequentemente:

$$E_{\text{MM},1} = |25,85 - 25,1| = 0,75^\circ\text{C}.$$

Para o filtro exponencial, no mesmo instante:

$$T_{F,1} = 25,71^\circ\text{C},$$

e, portanto:

$$E_{F,1} = |25,71 - 25,1| = 0,61^\circ\text{C}.$$

Esses são exatamente os valores determinados manualmente anteriormente.

Após a execução do código, a tabela deverá apresentar aproximadamente os seguintes resultados:

tempo_s	erro_original_C	erro_media_movel_C	erro_exponencial_C
0	0	0.50	0.50
1	1	1.10	0.610
2	2	0.20	0.437
3	3	2.00	0.906
4	4	1.10	0.304
5	5	1.80	0.145
6	6	0.50	0.049
7	7	2.20	0.626
8	8	1.20	0.022
9	9	1.50	0.435

A tabela permite realizar uma primeira comparação ponto a ponto entre os erros antes e depois da filtragem.

Por exemplo, no instante:

$$t_3 = 3\text{ s},$$

o erro do sinal original é:

$$E_{\text{abs},3} = 2,00^\circ\text{C}.$$

Após a aplicação da média móvel:

$$E_{MM,3} = 1,00^{\circ}\text{C},$$

enquanto, para o filtro exponencial:

$$E_{F,3} \approx 0,906^{\circ}\text{C}.$$

Nesse ponto específico, os dois sinais filtrados apresentam erros menores que o sinal original.

Entretanto, é importante observar que esse comportamento não ocorre necessariamente em todos os pontos.

No instante:

$$t_2 = 2\text{ s},$$

por exemplo, o sinal original apresenta:

$$E_{\text{abs},2} = 0,20^{\circ}\text{C},$$

enquanto a média móvel apresenta:

$$E_{MM,2} = 0,50^{\circ}\text{C},$$

e o filtro exponencial:

$$E_{F,2} = 0,437^{\circ}\text{C}.$$

Nesse instante específico, portanto, a medição original encontra-se mais próxima da referência do que os dois valores filtrados.

Esse resultado é importante para a interpretação da filtragem. O filtro atua sobre o comportamento temporal do sinal e não realiza uma correção ponto a ponto utilizando os valores do sensor de referência. Por isso, a redução das oscilações não implica necessariamente redução do erro em cada instante individual.

Para avaliar o efeito global dos filtros sobre o conjunto de dados, é necessário reunir os erros de todos os pontos em uma única medida de comparação. Para isso, no próximo passo serão determinados os erros absolutos médios do sinal original, da média móvel e do filtro exponencial.

7.4 Comparação dos erros absolutos médios

A comparação ponto a ponto realizada anteriormente mostrou que a aplicação de um filtro não produz necessariamente um erro menor em todos os instantes de medição.

Para avaliar o comportamento global de cada sinal em relação à referência, podemos calcular o erro absoluto médio.

Para o sinal original, essa grandeza já foi definida anteriormente por:

$$\overline{E}_{\text{original}} = \frac{1}{n} \sum_{k=1}^n E_{\text{abs},k}$$

e o resultado obtido foi:

$$\overline{E}_{\text{original}} = 1,21^{\circ}\text{C}$$

O mesmo procedimento pode ser aplicado aos erros obtidos após a aplicação dos dois filtros.

Erro absoluto médio da média móvel

Para o filtro de média móvel, define-se:

$$\overline{E}_{\text{MM}} = \frac{1}{n} \sum_{k=1}^n E_{\text{MM},k}$$

Os erros absolutos obtidos para os dez pontos são aproximadamente:

$$0,50, \quad 0,75, \quad 0,50, \quad 1,00, \quad 0,2333,$$

$$0,90, \quad 0,0667, \quad 1,1667, \quad 0,1667, \quad 0,8333.$$

Portanto:

$$\overline{E}_{\text{MM}} = \frac{0,50 + 0,75 + 0,50 + 1,00 + 0,2333 + 0,90 + 0,0667 + 1,1667 + 0,1667 + 0,8333}{10}.$$

A soma dos erros é aproximadamente:

$$\sum E_{\text{MM},k} = 6,1167^{\circ}\text{C}.$$

Logo:

$$\overline{E}_{\text{MM}} \approx 0,6117^{\circ}\text{C}$$

Erro absoluto médio do filtro exponencial

Para o filtro exponencial:

$$\overline{E}_F = \frac{1}{n} \sum_{k=1}^n E_{F,k}$$

Os erros absolutos correspondentes são aproximadamente:

0,5000, 0,6100, 0,4370, 0,9059, 0,3041,

0,7529, 0,3770, 0,9239, 0,2867, 0,6507.

Assim:

$$\overline{E}_F = \frac{0,5000 + 0,6100 + 0,4370 + 0,9059 + 0,3041 + 0,7529 + 0,3770 + 0,9239 + 0,2867 + 0,6507}{10}.$$

A soma dos erros é aproximadamente:

$$\sum E_{F,k} = 5,7483^\circ\text{C}.$$

Portanto:

$$\overline{E}_F \approx 0,5748^\circ\text{C}$$

Cálculo utilizando Python

Como as três colunas de erro já estão disponíveis no DataFrame, os erros absolutos médios podem ser determinados utilizando o método `mean()`:

```
##%
# -----
# 11. Comparação dos erros absolutos médios
# -----

# Erro absoluto médio do sinal original
erro_original_medio = (
    tabela["erro_original_C"].mean()
)

# Erro absoluto médio da média móvel
erro_media_movel_medio = (
    tabela["erro_media_movel_C"].mean()
)
```

```

# Erro absoluto médio do filtro exponencial
erro_exponencial_medio = (
    tabela["erro_exponencial_C"].mean()
)

# Apresentação dos resultados
print("-----")
print("Comparação dos erros absolutos médios")
print("-----")
print(
    f"Sinal original = "
    f"{erro_original_medio:.4f} °C"
)
print(
    f"Média móvel = "
    f"{erro_media_movel_medio:.4f} °C"
)
print(
    f"Filtro exponencial = "
    f"{erro_exponencial_medio:.4f} °C"
)
print("-----")

```

A saída esperada é:

```

-----
Comparação dos erros absolutos médios
-----
Sinal original = 1.2100 °C
Média móvel = 0.6117 °C
Filtro exponencial = 0.5748 °C
-----

```

Os resultados mostram que, para o conjunto de dados analisado, os dois sinais filtrados apresentam erro absoluto médio menor que o sinal original:

$$\overline{E}_{\text{original}} = 1,2100\text{ °C},$$

$$\overline{E}_{\text{MM}} \approx 0,6117\text{ °C},$$

e:

$$\overline{E}_F \approx 0,5748^\circ\text{C}.$$

Esses valores permitem quantificar uma característica que anteriormente havia sido observada apenas graficamente. Para este conjunto de dados e para os parâmetros de filtragem adotados, houve redução do erro absoluto médio após a aplicação dos dois filtros.

7.5 Redução percentual do erro absoluto médio

Além de comparar diretamente os valores dos erros absolutos médios, podemos determinar quanto cada filtro reduziu esse erro em relação ao sinal original.

Para a média móvel, a redução percentual pode ser definida por:

$$R_{\text{MM}} = \frac{\overline{E}_{\text{original}} - \overline{E}_{\text{MM}}}{\overline{E}_{\text{original}}} \times 100$$

Substituindo os valores:

$$R_{\text{MM}} = \frac{1,2100 - 0,6117}{1,2100} \times 100.$$

Portanto:

$$R_{\text{MM}} \approx 49,45\%$$

Para o filtro exponencial:

$$R_F = \frac{\overline{E}_{\text{original}} - \overline{E}_F}{\overline{E}_{\text{original}}} \times 100$$

Substituindo:

$$R_F = \frac{1,2100 - 0,5748}{1,2100} \times 100.$$

Logo:

$$R_F \approx 52,49\%$$

Esses cálculos também podem ser realizados em Python:

```
###
# -----
# 12. Redução percentual do erro
# -----

# Redução percentual com a média móvel
reducao_media_movel = (
```

```

(
erro_original_medio
- erro_media_movel_medio
)
/ erro_original_medio
) * 100

# Redução percentual com o filtro exponencial
reducao_exponencial = (
(
erro_original_medio
- erro_exponencial_medio
)
/ erro_original_medio
) * 100

# Apresentação dos resultados
print("-----")
print("Redução percentual do erro")
print("-----")
print(
f"Média móvel = "
f"{reducao_media_movel:.2f} %"
)
print(
f"Filtro exponencial = "
f"{reducao_exponencial:.2f} %"
)
print("-----")

```

A saída esperada é aproximadamente:

```

-----
Redução percentual do erro
-----
Média móvel = 49.45 %
Filtro exponencial = 52.49 %
-----

```

Portanto, para os dados utilizados neste exercício, a média móvel com $N = 3$ reduziu o erro absoluto médio em aproximadamente:

$$49,45\%$$

enquanto o filtro exponencial com $\alpha = 0,30$ produziu uma redução de aproximadamente:

$$52,49\%$$

É importante interpretar esses resultados dentro das condições específicas do exercício. Os percentuais obtidos dependem do conjunto de dados e dos parâmetros utilizados nos filtros, particularmente do tamanho da janela N e do fator de suavização α .

Assim, os resultados não estabelecem que um determinado método de filtragem será sempre superior ao outro. Eles mostram apenas o comportamento obtido para este conjunto de medições e para as configurações:

$$N = 3$$

e:

$$\alpha = 0,30.$$

A escolha de um filtro em uma aplicação real deve considerar não apenas a redução do erro observada em um conjunto de dados, mas também a capacidade de acompanhar alterações reais da variável medida, a dinâmica do processo e a finalidade para a qual o sinal será utilizado.

8. Síntese dos resultados

Após a caracterização do sinal original e a aplicação dos dois métodos de filtragem digital, os principais resultados obtidos podem ser reunidos para facilitar a comparação.

O sinal original apresentou erro absoluto médio de:

$$\overline{E}_{\text{original}} = 1,2100^\circ\text{C}.$$

Após a aplicação do filtro de média móvel com:

$$N = 3,$$

o erro absoluto médio foi reduzido para:

$$\overline{E}_{\text{MM}} \approx 0,6117^\circ\text{C}.$$

Para o filtro exponencial com:

$$\alpha = 0,30,$$

foi obtido:

$$\overline{E}_F \approx 0,5748^\circ\text{C}.$$

Esses resultados podem ser organizados na seguinte tabela:

Sinal	Erro absoluto médio ($^\circ\text{C}$)	Redução do erro (%)
Original	1,2100	–
Média móvel ($N = 3$)	0,6117	49,45
Filtro exponencial ($\alpha = 0,30$)	0,5748	52,49

A tabela permite visualizar diretamente o efeito produzido pelos dois métodos de filtragem. Em relação ao sinal original, ambos reduziram o erro absoluto médio para o conjunto de medições analisado.

Com a média móvel, o erro absoluto médio passou de:

$$1,2100^\circ\text{C}$$

para aproximadamente:

$$0,6117^\circ\text{C},$$

correspondendo a uma redução de aproximadamente:

$$49,45\%.$$

Com o filtro exponencial, o erro absoluto médio foi reduzido para aproximadamente:

$$0,5748^\circ\text{C},$$

o que corresponde a uma redução de aproximadamente:

$$52,49\%.$$

Para este conjunto de dados e para os parâmetros utilizados, portanto, os dois métodos produziram redução do erro absoluto médio, além da suavização das oscilações observada anteriormente nos gráficos.

O filtro exponencial apresentou, neste caso específico, erro absoluto médio ligeiramente menor que o obtido com a média móvel. A diferença entre os dois resultados é:

$$0,6117 - 0,5748 = 0,0369^\circ\text{C}.$$

Esse resultado deve ser interpretado dentro das condições estabelecidas no exercício. A comparação foi realizada utilizando uma média móvel com:

$$N = 3$$

e um filtro exponencial com:

$$\alpha = 0,30.$$

Alterações nesses parâmetros podem modificar tanto o grau de suavização quanto os erros obtidos em relação à referência.

Além disso, os cálculos ponto a ponto mostraram que a filtragem não reduz necessariamente o erro em cada instante individual. O objetivo dos filtros utilizados é processar o sinal medido considerando informações de amostras anteriores, e não corrigir diretamente cada medição utilizando o valor do sensor de referência.

Assim, a análise realizada neste exercício permite distinguir dois aspectos importantes da filtragem digital:

suavização do sinal $\neq$ redução garantida do erro em cada ponto

e, ao mesmo tempo, mostra que a qualidade do resultado pode ser avaliada quantitativamente comparando o sinal processado com uma referência disponível.

Neste exercício, essa comparação mostrou que, para os dados e parâmetros adotados, os dois métodos de filtragem reduziram o erro absoluto médio do sinal medido.